

# Fundamentos de Inferência Bayesiana

Victor Fossaluza

2020-08-11



# Sumário

<b>1</b>	<b>Probabilidade Subjetiva</b>	<b>5</b>
1.1	Definição Axiomática . . . . .	5
1.2	Interpretações de Probabilidade . . . . .	5
1.3	Relação de Crença $\succsim$ . . . . .	6
1.4	Suposições sobre $\succsim$ . . . . .	7
1.5	Medida de Probabilidade que “representa” $\succsim$ . . . . .	9
1.6	Medida de Probabilidade Condicional . . . . .	11
<b>2</b>	<b>Introdução à Inferência Bayesiana</b>	<b>13</b>
2.1	Notação . . . . .	13
2.2	Inferência Clássica (ou Frequentista) . . . . .	13
2.3	Inferência Bayesiana . . . . .	14
2.4	Distribuição a Priori . . . . .	17
<b>3</b>	<b>Apendice: Breve Resumo de Medida e Probabilidade</b>	<b>23</b>
3.1	Breve Resumo de Medida e Probabilidade . . . . .	23
3.2	Valor Esperado de $X$ (OU uma ideia da tal Integral de Lebesgue) . . . . .	25
3.3	Propriedades da integral ( <i>de Lebesgue</i> ) de $X$ (v.a) em relação a $P$ . . . . .	26
3.4	Funções de Variáveis Aleatórias . . . . .	29
3.5	Aula 6 . . . . .	31
3.6	Aula 7 . . . . .	34

Essas notas de aula tem o intuito apenas de ser um guia de estudos e não necessariamente irá apresentar todo o conteúdo da disciplina de *Inferência Bayesiana*. Além disso, esta é uma versão preliminar e está bem longe de ser uma versão final, de modo que podem haver muitos erros e correções ou sugestões serão bem vindas!



# Capítulo 1

## Probabilidade Subjetiva

A construção de probabilidade subjetiva apresentada aqui pode ser encontrada em DeGroot (1970).


- $\Omega$ : *espaço amostral*, conjunto não vazio.
- $\mathcal{A}$ :  $\sigma$ -álgebra de subconjuntos de  $\Omega$ , isto é,
  1.  $\Theta \in \mathcal{A}$ ;
  2.  $A \in \mathcal{A} \implies A^c \in \mathcal{A}$ ;
  3.  $A_1, A_2, \dots \in \mathcal{A} \implies \bigcup_{i \geq 1} A_i \in \mathcal{A}$ .
- Os elementos de  $\mathcal{A}$  são chamados de *eventos* e serão denotados por  $A, B, C, \dots, A_1, A_2, \dots$

### 1.1 Definição Axiomática

- $P : \mathcal{A} \longrightarrow [0, 1]$  é uma *medida de probabilidade* se
  1.  $P(\Omega) = 1$ ;
  2.  $A_1, A_2, \dots \in \mathcal{A}$  com  $A_i \cap A_j = \emptyset$ ,  $P\left(\bigcup_{i \geq 1} A_i\right) = \sum_{i \geq 1} P(A_i)$ .

### 1.2 Interpretações de Probabilidade

- **Interpretação Clássica** (De Moivre, Laplace)
  - baseia-se na equiprobabilidade dos resultados;
  - $P(A) = \frac{|A|}{|\Omega|}$ .
  - **Exemplo:** um lançamento de moeda,  $A = \text{“cara”}$ ,  $P(A) = \frac{1}{2}$ .
- **Interpretação Frequentista** (Venn, von Mises, Reichenbach, etc.)
  - quase unânime na primeira metade do século XX e ainda é a mais aceita;
  - baseia-se na regularidade das frequências relativas (lei dos grandes números);
  - $P(A) = \lim \frac{A_n}{n}$ , onde  $A_n$  é o número de ocorrências de  $A$  em  $n$  realizações *idênticas e independentes* do experimento;
  - Supõe que é possível repetir indefinidamente o experimento nas mesmas circunstâncias.
  - **Exemplo:** um lançamento de moeda,  $A = \text{“cara”}$ .



- **Interpretação Lógica** (Keynes, Jeffreys, Carnap, etc.)
  - medida de “vínculo parcial” entre uma evidência e uma hipótese;
  - baseia-se em relações objetivas entre proposições.
  - **Exemplo:** considere duas proposições: “até agora todos os lançamentos resultaram em cara” e “será realizado um novo lançamento”. Pode-se afirmar que “provavelmente o resultado do novo lançamento será cara”.
  
- **Interpretação Subjetivista** (Ramsey, de Finetti, Savage, etc)
  - probabilidade como medida subjetiva de crença;
  - baseada na experiência de cada indivíduo, portanto única.
  - **Exemplo:** suponha que Bruno lançou uma moeda 3 vezes e todos os resultados foram cara. Esse indivíduo, em posse dessa informação, pode acreditar que o resultado cara é mais provável que coroa. Contudo, quando pergunta sobre a probabilidade de cara ao seu colega Olavo, ignorante com relação a moeda, ele responde que é  $1/2$ .

### 1.3 Relação de Crença $\precsim$

$\precsim$  : relação de “crença” em  $\mathcal{A} \times \mathcal{A}$

- $A \prec B$  : acredito mais em  $B$  que em  $A$  ( $B \succ A$ )
- $A \sim B$  : acredito igualmente em  $B$  e  $A$
- $A \precsim B$  : acredito em  $B$  pelo menos tanto quanto em  $A$

**Objetivo:** sob certas condições em  $\precsim$ , obter uma medida de probabilidade  $P$  que representa (concorda) com  $\precsim$ .

$$A \precsim B \iff P(A) \leq P(B)$$

## 1.4 Suposições sobre $\preceq$

**SP1:** Para  $A, B \in \mathcal{A}$ , exatamente uma das afirmações a seguir deve valer:

$$A \prec B, B \prec A \text{ ou } A \sim B.$$

**SP2:**  $A_1, A_2, B_1, B_2 \in \mathcal{A}$  tais que  $A_1 \cap A_2 = B_1 \cap B_2 = \emptyset$  e  $A_i \preceq B_i, i = 1, 2$ . Então

$$A_1 \cup A_2 \preceq B_1 \cup B_2.$$

Além disso, se  $A_i \prec B_i$  para algum  $i$ , então  $A_1 \cup A_2 \prec B_1 \cup B_2$ .

**SP3:** Se  $A$  é um evento, então  $\emptyset \preceq A$ . Além disso,  $\emptyset \prec \Omega$ .

**SP4:** Se  $A_1, A_2, \dots$  uma sequência decrescente de eventos, isto é,  $A_n \supseteq A_{n+1}, \forall n$ , e  $B$  tal que  $B \preceq A_n, \forall n$  então

$$B \preceq \bigcap_{n \geq 1} A_n.$$

**SP5:** Existe uma variável aleatória  $X : \Omega \rightarrow \mathbb{R}$ ,  $\mathcal{A}$ -mensurável, tal que  $X(\omega) \in [0, 1], \forall \omega \in \Omega$  e, se  $I_1$  e  $I_2$  são intervalos contidos em  $[0, 1]$ ,  $\{X \in I_1\} \preceq \{X \in I_2\} \Leftrightarrow \lambda(I_1) \leq \lambda(I_2)$ .

- Se  $I = [a, b] \subseteq [0, 1]$ ,  $\lambda(I) = b - a$  é o comprimento do intervalo  $I$  (medida de Lebesgue).
- “Experimento auxiliar” ;  $X \sim \text{Uniforme}[0, 1]$ .
- $\{X \in [a, b]\} \sim \{X \in (a, b]\} \sim \{X \in [a, b)\} \sim \{X \in (a, b)\}$ .

**Lema 1:**  $A, B, D \in \mathcal{A}$  tais que  $A \cap D = B \cap D = \emptyset$ . Então

$$A \preceq B \Leftrightarrow A \cup D \preceq B \cup D$$


**Demo:**

$$(\Rightarrow) A \preceq B \Rightarrow A \cup D \preceq B \cup D \text{ (SP2)}$$

$$(\Leftarrow) B \prec A \Rightarrow B \cup D \prec A \cup D \text{ (SP2)}$$

**Teorema 1:** Se  $A \preceq B$  e  $B \preceq D$  então  $A \preceq D$ .

**Demo:**



- (i)  $(1) \cup (2) \cup (4) \cup (5) \preceq (1) \cup (2) \cup (3) \cup (6) \Rightarrow (4) \cup (5) \preceq (3) \cup (6)$ .
- (ii) Analogamente,  $(2) \cup (6) \preceq (4) \cup (7)$   
 De (i) e (ii) e pelo Lema 1,  $(4) \cup (5) \cup (2) \cup (6) \preceq (3) \cup (6) \cup (4) \cup (7)$   
 $\Rightarrow (2) \cup (5) \preceq (3) \cup (7) \Rightarrow (2) \cup (5) \cup (1) \cup (4) \preceq (3) \cup (7) \cup (1) \cup (4)$ .

**Teorema 2 (generalização do SP2):** Se  $A_1, \dots, A_n$  são eventos disjuntos e  $B_1, \dots, B_n$  são também eventos disjuntos tais que  $A_i \preceq B_i$ , para  $i = 1, \dots, n$ , então

$$\bigcup_{i=1}^n A_i \preceq \bigcup_{i=1}^n B_i.$$

Se  $A_i \prec B_i$  para algum  $i$ , então  $\bigcup_{i=1}^n A_i \prec \bigcup_{i=1}^n B_i$ .

**Demo:** Exercício.

**Teorema 3:** Se  $A \preceq B$  então  $A^c \succeq B^c$ .

**Demo:** Do Lema 1,  $A \cup (A^c \cap B^c) \preceq B \cup (A^c \cap B^c) \Rightarrow B^c \cup (A \cap B) \preceq A^c \cup (A \cap B) \Rightarrow B^c \preceq A^c$ .

**Resultado:** Para todo evento  $A$ ,  $A \preceq \Omega$ .

**Demo:** Por SP3,  $\emptyset \preceq A^c$ . Tomando  $D = A$  no Lema 1,  $\emptyset \cup A \preceq A^c \cup A \Rightarrow A \preceq \Omega$ .

**Teorema 4:** Se  $A \subseteq B$  então  $A \preceq B$ .

**Demo:** Suponha,  $B \prec A$ . Tomando  $D = B^c$  no Lema 1,  $B \cup B^c \prec A \cup B^c \Rightarrow \Omega \prec A \cup B^c$ . Absurdo!

**Exemplo 1:**  $\omega_0 \in \Omega$ .  $A \preceq B \Leftrightarrow \{\omega_0 \in B \text{ ou } \omega_0 \notin (A \cup B)\}$ . Mostre que  $\preceq$  obedece a SP1 a SP4.

(SP1)

$$A \preceq B \Leftrightarrow \omega_0 \in B \cup (A \cup B)^c \Rightarrow B \prec A \Leftrightarrow \omega_0 \in B^c \cap (A \cup B) \Leftrightarrow \omega_0 \in A \cap B^c.$$

Analogamente,  $A \prec B \Leftrightarrow \omega_0 \in B \cap A^c$ .

$$A \sim B \Leftrightarrow A \preceq B \text{ e } B \preceq A \Leftrightarrow \omega_0 \in [B \cup (A \cup B)^c] \cap [A \cup (A \cup B)^c] \Leftrightarrow \omega_0 \in (A \cap B) \cup (A \cup B)^c.$$

(SP2)

$$A_i \preceq B_i, i = 1, 2 \Leftrightarrow \omega_0 \in [B_1 \cup (A_1 \cup B_1)^c] \cap [B_2 \cup (A_2 \cup B_2)^c] \Leftrightarrow \omega_0 \in [(B_1 \cup B_2) \cap D^c] \cup (A_1 \cup B_1 \cup A_2 \cup B_2)^c,$$

com  $D = (A_1 \cap B_2) \cup (A_2 \cap B_1)$ .

$$A_1 \cup A_2 \preceq B_1 \cup B_2 \Leftrightarrow \omega_0 \in (B_1 \cup B_2) \cup (A_1 \cup A_2 \cup B_1 \cup B_2)^c$$

Como  $(B_1 \cup B_2) \cap D^c \subseteq (B_1 \cup B_2)$ , vale o SP2.

(SP3)

$$\emptyset \preceq A \Leftrightarrow \omega_0 \in A \cup (\emptyset \cup A)^c \Leftrightarrow \omega_0 \in A \cup A^c = \Omega.$$

Como  $\Omega$  é não-vazio,  $\exists \omega_0 \in \Omega$  e, portanto,  $\emptyset \prec \Omega$ .

(SP4) Exercício!



**Exemplo 2:**  $\Omega = \mathbb{N}$ ,  $\mathcal{A} = \mathcal{P}(\mathbb{N})$ .  $A \preceq B \Leftrightarrow \{B \text{ é infinito ou } A \text{ e } B \text{ são finitos com } |A| \leq |B|\}$ . Verifique se  $\preceq$  satisfaz SP1 a SP4.

**Teorema 5:** Se  $A_1 \subseteq A_2 \subseteq \dots$  é uma sequência crescente de eventos e  $B$  é tal que  $A_n \preceq B, \forall n$  então

$$\bigcup_{n \geq 1} A_n \preceq B.$$

**Demo:**  $A_n^c \supseteq A_{n+1}^c$  e, pelo Teo 3,  $A_n^c \preceq B^c, \forall n$ .

Por SP4,  $\bigcap_{n \geq 1} A_n^c \preceq B^c \Rightarrow \bigcup_{n \geq 1} A_n \preceq B$ .

**Teorema 6:**  $(A_n)_{n \geq 1}$  e  $(B_n)_{n \geq 1}$  sequências tais que  $A_i \cap A_j = B_k \cap B_l = \emptyset, \forall i \neq j, \forall k \neq l$ .

$$A_i \preceq B_i, \forall i \Rightarrow \bigcup_{n \geq 1} A_n \preceq \bigcup_{n \geq 1} B_n.$$

Se existe ao menos um  $j$  tal que  $A_j \prec B_j$  então  $\bigcup_{n \geq 1} A_n \prec \bigcup_{n \geq 1} B_n$ .

**Demo:** Da extensão de SP2, temos que  $\bigcup_{i=1}^n A_i \preceq \bigcup_{i=1}^n B_i, \forall n \geq 1 \Rightarrow \bigcup_{i=1}^n A_i \preceq \bigcup_{i=1}^{\infty} B_i, \forall n \geq 1$

$\Rightarrow \bigcup_{i=1}^{\infty} A_i \preceq \bigcup_{i=1}^{\infty} B_i$  (Teo 5)

$\exists n_0$  tal que  $A_{n_0} \prec B_{n_0}$ . De SP2, temos que, para  $n \geq n_0$ ,

$$\bigcup_{i=1}^{n_0} A_i = \bigcup_{i=1}^{n_0-1} A_i \cup A_{n_0} \prec \bigcup_{i=1}^{n_0-1} B_i \cup B_{n_0} = \bigcup_{i=1}^{n_0} B_i \Rightarrow \bigcup_{i=1}^{n_0} A_i \prec \bigcup_{i=1}^{n_0} B_i.$$

Da primeira parte, temos que  $\bigcup_{i=n_0+1}^{\infty} A_i \preceq \bigcup_{i=n_0+1}^{\infty} B_i$  e, por SP2,

$$\bigcup_{i=1}^{n_0} A_i \cup \bigcup_{i=n_0+1}^{\infty} A_i \prec \bigcup_{i=1}^{n_0} B_i \cup \bigcup_{i=n_0+1}^{\infty} B_i$$

provando o resultado.

## 1.5 Medida de Probabilidade que “representa” $\preceq$

**Teorema 7:** Seja  $A \in \mathcal{A}$ . Então  $\exists! a^* \in [0, 1]$  tal que  $A \sim \{X \in [0, a^*]\}$ .

**Demo:** Seja  $U(A) = \{a \in [0, 1] : A \preceq \{X \in [0, a]\}\}$ .

$1 \in U(A)$  pois  $\Omega = \{X \in [0, 1]\} \preceq A \Rightarrow U(A) \neq \emptyset$ .

Tome  $a^* = \inf U(A)$ .

(i) Considere  $(a_n)_{n \geq 1}$ ,  $a_n \in [0, 1], \forall n \geq 1$ , tal que  $a_n \geq a_{n+1} \geq a^*$  e  $a_n \downarrow a^*$ . Então,  $\forall n \geq 1$ ,  $\{X \in [0, a_n]\} \preceq A$ .

Por SP4,  $\bigcap_{n=1}^{\infty} \{X \in [0, a_n]\} \preceq A \Rightarrow \{X \in [0, a^*]\} \preceq A$

(ii) Se  $a^* = 0$ ,  $\{X \in [0, 0]\} \sim \emptyset \preceq A$  (por SP3).

Se  $a^* > 0$ , considere  $(a_n)_{n \geq 1}$  com  $a_n \leq a_{n+1} < a^*$  e  $a_n \uparrow a^*$ .

$\{X \in [0, a_n]\} \preceq A, \forall n \geq 1$  e, pelo Teo 5,  $\bigcup_{n=1}^{\infty} \{X \in [0, a_n]\} \preceq A \Rightarrow \{X \in [0, a^*]\} \sim \{X \in [0, a^*]\} \preceq A$ .

De (i) e (ii), temos que  $A \sim \{X \in [0, a^*]\}$ .

$a^*$  é único pois se  $a_1 < a^* < a_2$  são outros valores quaisquer, segue que  $\{X \in [0, a_1]\} \prec \{X \in [0, a^*]\} \prec \{X \in [0, a_2]\}$  e só um desses eventos pode ser equivalente à  $A$ .

**Teorema 8:** A probabilidade do evento  $A$ ,  $P(A)$ , é definida como  $a^* \in [0, 1]$  tal que  $A \sim \{X \in [0, a^*]\}$ . Assim,  $A \sim \{X \in [0, P(A)]\}$ . A função de probabilidade assim definida satisfaz:

$$A \preceq B \Leftrightarrow P(A) \leq P(B).$$

**Demo:** Do Teo 7,  $A \sim \{X \in [0, P(A)]\}$  e  $B \sim \{X \in [0, P(B)]\}$ .

$$\begin{aligned} A \preceq B &\Leftrightarrow \{X \in [0, P(A)]\} \preceq \{X \in [0, P(B)]\} \Leftrightarrow \lambda([0, P(A)]) \preceq \lambda([0, P(B)]) \\ &\Leftrightarrow P(A) \leq P(B). \end{aligned}$$

**Teorema 9:** A função  $P : \mathcal{A} \rightarrow [0, 1]$  que, para cada  $A \in \mathcal{A}$ , associa  $P(A)$  tal que  $A \sim \{X \in [0, P(A)]\}$  é uma medida de probabilidade (no sentido  $\sigma$ -aditiva).

**Demo:** (i)  $P(A) \geq 0$ .

$$\Omega \sim \{X \in [0, 1]\} \Rightarrow P(\Omega) = 1.$$

$$\emptyset \sim \{X \in [0, 0]\} \Rightarrow P(\emptyset) = 0$$

$$\emptyset \preceq A \Rightarrow 0 \leq P(A).$$

(ii) Seja  $A$  e  $B$  tal que  $A \cap B = \emptyset$ . Vamos mostrar que  $P(A \cup B) = P(A) + P(B)$ .

Pelo Teo 8,  $A \sim \{X \in [0, P(A)]\}$ ,  $B \sim \{X \in [0, P(B)]\}$ ,  $A \cup B \sim \{X \in [0, P(A \cup B)]\}$ .

Como  $A \subseteq A \cup B$  e, por SP3,  $A \preceq A \cup B$ , vale que  $P(A) \leq P(A \cup B)$ . Vamos verificar que  $B \sim \{X \in (P(A), P(A \cup B)]\}$ .

Suponha, por absurdo,  $B \prec \{X \in (P(A), P(A \cup B)]\}$ .

$$\begin{aligned} A \preceq \{X \in [0, P(A)]\} &\xrightarrow{SP2} A \cup B \prec \{X \in [0, P(A)]\} \cup \{X \in (P(A), P(A \cup B)]\} \\ \Rightarrow A \cup B \prec \{X \in [0, P(A)] \cup (P(A), P(A \cup B)]\} &\Rightarrow A \cup B \prec \{X \in [0, P(A \cup B)]\} \sim \\ (\text{Absurdo!}) & \end{aligned}$$

Analogamente,  $B \succ \{X \in (P(A), P(A \cup B)]\}$  é absurdo! Logo,  $B \sim \{X \in (P(A), P(A \cup B)]\} \sim \{X \in [0, P(A \cup B) - P(A)]\}$ .

Como  $B \sim \{X \in [0, P(B)]\}$ , temos que  $P(A \cup B) = P(A) + P(B)$ .

**Corolário 1:** Se  $A_1, \dots, A_n$  são eventos disjuntos, então  $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$ .

**Demo:** Indução.

**Teorema 10:** Seja  $A_1 \supseteq A_2 \supseteq \dots$  uma seq. decrescente de eventos tais que  $\bigcap_{i=1}^{\infty} A_i = \emptyset$ . Então  $\lim_{n \uparrow \infty} P(A_n) = 0$ .

**Demo:**  $A_1 \supseteq A_2 \supseteq \dots \Rightarrow P(A_1) \geq P(A_2) \geq \dots$

Além disso,  $\lim_{n \uparrow \infty} P(A_n) = b$ . Como  $P(A_n) \geq b, \forall n$ , segue que  $A_n \succeq \{X \in [0, b]\}, \forall n$ .

Por SP4,  $\emptyset = \bigcap_{i=n}^{\infty} A_i \succeq \{X \in [0, b]\}$ .

Se  $b > 0$ , então  $\{X \in [0, b]\} \succ \{X \in [0, b/2]\} \succeq \emptyset$ . Como essa relação contradiz a anterior, temos que  $b$  deve ser igual a 0.

**Exercício 1:** Use o Corolário 1 e o Teorema 10 para concluir a demonstração do Teorema 9, mostrando que  $P$  é  $\sigma$ -aditiva, isto é,

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i) \quad , \quad A_i \cap A_j = \emptyset, \forall i \neq j.$$

**Solução:** Seja  $(A_n)_{n \geq 1}$  sequência de eventos disjuntos. Segue do Corolário 1 que

$$(i) \quad P\left(\bigcup_{i=1}^{\infty} A_n\right) = \sum_{i=1}^n P(A_i) + P\left(\bigcup_{j=n+1}^{\infty} A_j\right), \quad n = 1, 2, \dots$$

Considere  $B_n = \bigcup_{j=n+1}^{\infty} A_j$ ,  $n \geq 1$ , uma sequência decrescente de eventos tais que  $\bigcap_{n=1}^{\infty} B_n = \emptyset$ .

Pelo Teorema 10, segue que  $\lim_{n \uparrow \infty} B_n = \emptyset$ . Assim, tomando o limite do lado direito de (i), segue que

$$P\left(\bigcup_{i=1}^{\infty} A_n\right) = \lim_{n \uparrow \infty} \sum_{i=1}^n P(A_i) + \lim_{n \uparrow \infty} P(B_n) = \sum_{i=1}^{\infty} P(A_i).$$

**Teorema 11:** Se a relação de crença  $\preceq$  obedece SP1 a SP5 então  $\exists!$   $P : \mathcal{A} \rightarrow [0, 1]$ , medida de probabilidade, tal que  $P$  representa  $\preceq$ .

**Demo:** Exercício!

## 1.6 Medida de Probabilidade Condicional

**Nova Relação:**  $(A|D) \preceq (B|D)$  (Sabendo que  $D$  ocorreu,  $B$  é preferível a  $A$ ).

- Para  $D = \Omega$ , temos o caso anterior:  $A \preceq B \Leftrightarrow (A|\Omega) \preceq (B|\Omega)$ .
- Suponha que vale as suposições SP1 a SP5 e, adicionalmente,

**SP6:**  $(A|D) \preceq (B|D) \Leftrightarrow (A \cap D) \preceq (B \cap D) \quad \left( (A \cap D|\Omega) \preceq (B \cap D|\Omega) \right)$

**Teorema 12:**  $\forall A, B, D \in \mathcal{A}$ , considere  $\preceq$  satisfazendo SP1 a SP6. Então  $P : \mathcal{A} \rightarrow [0, 1]$  de modo que para cada  $A \in \mathcal{A}$  é associada  $P(A) \in [0, 1]$  tal que  $A \sim \{X \in [0, P(A)]\}$  é uma medida de probabilidade que representa  $\preceq$ , isto é,

$$(A|\Omega) \preceq (B|\Omega) \Leftrightarrow P(A) \leq P(B).$$

Além disso, se  $D \in \mathcal{A}$  é tal que  $P(D) > 0$ , então

$$(A|D) \preceq (B|D) \Leftrightarrow P(A|D) \leq P(B|D),$$

onde  $P(\cdot|D) : \mathcal{A} \rightarrow [0, 1]$  é uma medida de probabilidade tal que

$$P(A|D) = \frac{P(A \cap D)}{P(D)}.$$



## Capítulo 2

# Introdução à Inferência Bayesiana

### 2.1 Notação

- **Inferência Estatística:** fazer afirmações sobre quantidades não observáveis em um determinado contexto.
- $\theta$  : **parâmetro** - quantidade desconhecida de interesse (não-observável em determinado contexto).
- $\Theta$  : **espaço paramétrico** - conjunto onde  $\theta$  toma valores (supostamente conhecido).
- $E = (X, \theta, \{f(x|\theta)\})$ : **experimento** - “*tornar visível algo que antes era invisível*” ou, mais especificamente no nosso contexto, observar uma realização  $x \in \mathfrak{X}$  de um vetor aleatório  $X$  com alguma distribuição  $f(x|\theta)$ . Essa distribuição pertence, na maioria dos casos, à uma família de distribuições fixada mas que depende do parâmetro desconhecido de interesse  $\theta$ . Note que na grande maioria dos problemas do dia a dia de um estatístico ele se utiliza de resultados experimentais para fazer afirmações sobre  $\theta$  e este, por sua vez, é não-observável em geral.
- $\mathfrak{X}$  : **espaço amostral** - conjunto onde  $X$  toma valores (supostamente conhecido).
- $\mathcal{F}$  :  $\sigma$ -álgebra de (sub)conjuntos de  $\mathfrak{X}$ .
- Neste espaço amostral, defini-se uma família  $\mathcal{P} = \{P(\cdot|\theta) : \theta \in \Theta\}$ , isto é, um conjunto de distribuições (condicionais) para  $X$  indexadas por  $\theta$ .
- $(\mathfrak{X}, \mathcal{F}, \mathcal{P})$  : modelo estatístico (clássico).
- $V_X(\theta) = f(x|\theta)$  : função de verossimilhança.

### 2.2 Inferência Clássica (ou Frequentista)

- $\theta$  é considerado fixo (apesar de desconhecido) e, portanto, não recebe uma distribuição de probabilidade.
- Baseia-se no “princípio” da amostragem repetida (interpretação frequentista de probabilidade), isto é, supõe que é possível realizar infinitas vezes o experimento. Assim, o  $x$  é apenas um dos possíveis resultados (hipótéticos) do experimento.
- Probabilidade somente é definida em (uma  $\sigma$ -álgebra de)  $\mathfrak{X}$ .

## 2.3 Inferência Bayesiana

- Baseia-se na interpretação subjetivista de probabilidade, de modo que a *SUA* incerteza sobre algo desconhecido deve ser quantificada (traduzida) em termos de probabilidade.
- Assim, Sua incerteza sobre o parâmetro (desconhecido) é representada por uma distribuição de probabilidade,  $\theta$  é tratado como uma v.a. e *SUA* distribuição para  $\theta$  antes da realização do experimento,  $f(\theta)$ , é chamada de **distribuição a priori**. Note que a atribuição de uma distribuição a priori para  $\theta$  independe da natureza do parâmetro, ele pode ser a proporção de indivíduos que avalia positivamente o governo atual (quantidade essa que muda a todo instante) ou ainda a milésima casa do  $\pi$  (algum número de 0 a 9, fixo porém desconhecido no momento dessa leitura).
- A atualização de *SUA* incerteza sobre  $\theta$ , incorporando uma nova informação trazida pelos dados  $x$  (representada por  $f(x|\theta)$ ) é feita pelo *Teorema de Bayes*:
- **Teorema de Bayes:**

$$\underbrace{f(\theta|x)}_{\text{dist.posteriori}} = \frac{f(\theta)f(x|\theta)}{\int_{\Theta} f(x|\theta)dP_{\theta}} \propto \underbrace{f(\theta)}_{\text{priori}} \overbrace{f(x|\theta)}^{\text{verossimilhana}}.$$

- Toda a inferência sobre  $\theta$  será baseada exclusivamente em  $f(\theta|x)$ , não sendo necessário considerar pontos amostrais que poderiam mas não foram observados (como é feito na inferência frequentista).
- **Observação:** será utilizada a notação geral para integral (de Lebesgue):

$$\int_{\Theta} f(x|\theta)dP_{\theta} = \begin{cases} \int_{\Theta} f(x|\theta)f(\theta)d\theta & (\text{caso contínuo}) \\ \sum_{\Theta} f(x|\theta)f(\theta) & (\text{caso discreto}) \end{cases}$$


**Exemplo 1.a:** Suponha que existem duas moedas, uma delas tem  $\theta = 1/2$  (honestas) e a outra  $\theta = 3/4$  (viesada). Uma moeda é escolhida e é feito um lançamento da moeda selecionada. Nesse experimento, tem-se  $X|\theta \sim \text{Ber}(\theta)$ , com  $\Theta = \{1/2, 3/4\}$  e  $\mathcal{X} = \{0, 1\}$ . Como “chutar” o valor de  $\theta$ ?

Considere que não existe razão para você acreditar que há algum tipo de preferência na escolha de uma ou outra moeda, isto é, considere que a priori  $f(\theta = 1/2) = f(\theta = 3/4) = 1/2$ . Suponha que o lançamento resultou em cara ( $x = 1$ ). Então

$$f(\theta = 3/4|X = 1) = \frac{f(X = 1|\theta = 3/4)f(\theta = 3/4)}{\sum_{\theta} f(X = 1|\theta)f(\theta)} = \frac{\frac{3}{4} \frac{1}{2}}{\frac{3}{4} \frac{1}{2} + \frac{1}{2} \frac{1}{2}} = \frac{3/4}{5/4} = \frac{3}{5} = 1 - \underbrace{f(\theta = 1/2|X = 1)}_{2/5}$$

Se, no entanto, o resultado do lançamento da moeda fosse coroa ( $x = 0$ ), teríamos

$$P(\theta = 3/4|X = 0) = \frac{\frac{1}{4} \frac{1}{2}}{\frac{1}{4} \frac{1}{2} + \frac{1}{2} \frac{1}{2}} = \frac{1/2}{1/2 + 2/2} = \frac{1}{3}$$




Assim, se sua decisão for escolher o valor mais provável de  $\theta$  após observar  $x$ , a conclusão seria que a moeda é viesada ( $\theta = 3/4$ ) se for observado cara ( $x = 1$ ) e que a moeda é honesta ( $\theta = 1/2$ ) se o resultado for coroa ( $x = 0$ ).

**Exemplo 1.b:** Considere agora que serão realizados  $n$  lançamentos da moeda, de modo que agora tem-se  $X|\theta \sim \text{Bin}(n, \theta)$ ,  $\theta \in \{1/2, 3/4\}$ ,  $x \in \{0, 1, \dots, n\}$ . Suponha que observa-se  $X = x$ .

$$f(\theta = 3/4 | X = x) = \frac{f(x|\theta = 3/4)f(\theta = 3/4)}{\sum_{\theta \in \{1/2, 3/4\}} f(x|\theta)f(\theta)} = \frac{\binom{n}{x} \left(\frac{3}{4}\right)^x \left(\frac{1}{4}\right)^{n-x} \frac{1}{2}}{\binom{n}{x} \left(\frac{3}{4}\right)^x \left(\frac{1}{4}\right)^{n-x} \frac{1}{2} + \binom{n}{x} \left(\frac{1}{2}\right)^x \left(\frac{1}{2}\right)^{n-x} \frac{1}{2}} =$$

$$\frac{1}{1 + \left(\frac{2^n}{3^x}\right)} = \frac{3^x}{3^x + 2^n}.$$



Note que o Exemplo 1.a é um caso particular desse exemplo quando  $n = 1$ . Se novamente sua decisão é baseada no valor mais provável de  $\theta$ , temos

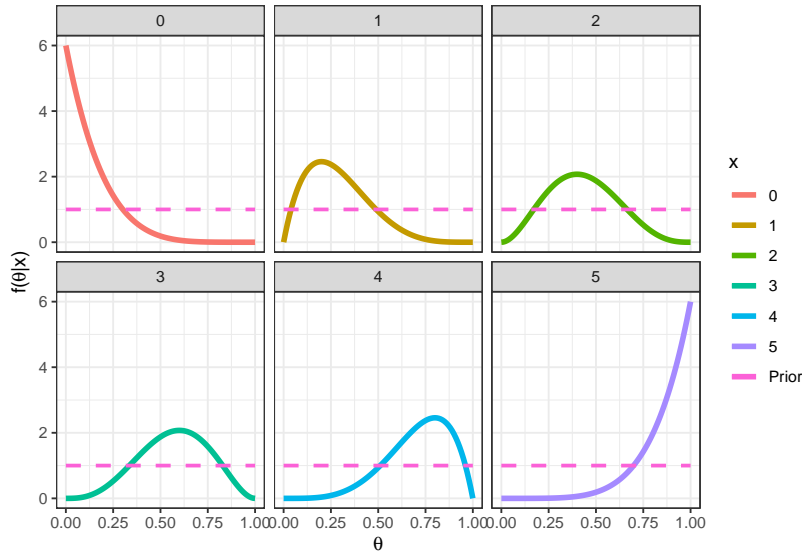
$$f(\theta = 3/4 | X = x) > \frac{1}{2} \iff \frac{3^x}{3^x + 2^n} > \frac{1}{2} \iff 3^x > 2^n \iff \frac{x}{n} = \bar{x} > \log_3 2 \approx 0,63.$$

**Exemplo 1.c:** Considere uma moeda será lançada  $n$  vezes mas que  $\theta$  é desconhecido, de modo que  $\Theta = [0, 1]$ . Para simplificar, vamos assumir  $f(\theta) = \mathbb{I}_{[0,1]}(\theta)$ , isto é,  $\theta \sim Unif(0, 1) \sim Beta(1, 1)$ . Essa priori corresponde ao caso onde você acredita que todos os valores possíveis para  $\theta$  são igualmente “prováveis”, assim como nos exemplos anteriores. Novamente,  $X|\theta \sim Bin(n, \theta)$

$$\begin{aligned} f(\theta|x) &= \frac{f(x|\theta)f(\theta)}{\int_0^1 f(x|\theta)f(\theta)d\theta} = \frac{\binom{n}{x}\theta^x(1-\theta)^{n-x} \mathbb{I}_{[0,1]}(\theta)}{\int_0^1 \binom{n}{x}\theta^x(1-\theta)^{n-x}d\theta} = \frac{\frac{\Gamma(1+x)\Gamma(1+n-x)}{\Gamma(1+x)\Gamma(1+n-x)} \theta^x(1-\theta)^{n-x} \mathbb{I}_{[0,1]}(\theta)}{\underbrace{\int_0^1 \frac{\Gamma(1+x)\Gamma(1+n-x)}{\Gamma(1+x)\Gamma(1+n-x)} \theta^x(1-\theta)^{n-x}d\theta}_1} \\ &= \frac{\Gamma(1+x)\Gamma(1+n-x)}{\Gamma(1+x)\Gamma(1+n-x)} \theta^x(1-\theta)^{n-x} \mathbb{I}_{[0,1]}(\theta). \end{aligned}$$

Logo  $\theta|x \sim Beta(1+x, 1+n-x)$ . Nesse exemplo, o valor “mais provável” (com maior densidade a posteriori) para  $\theta$  é a moda da distribuição,  $Moda(\theta|x) = \frac{(1+x)-1}{(1+x)+(1+n-x)-2} = \frac{x}{n} = \bar{x}$ .

**Exemplo 1.d** Por fim, suponha que no exemplo anterior, sua opinião a priori é representada por uma distribuição beta qualquer com parâmetros  $a$  e  $b$ ,  $a, b > 0$ . Desta forma,  $X|\theta \sim Bin(n, \theta)$  e  $\theta \sim Beta(a, b)$ . Calculando a distribuição a posteriori de forma similar ao exemplo anterior, temos que  $\theta|X = x \sim Beta(a+x, b+n-x)$ .



Suponha que  $a = b = 1$  (como no exemplo anterior),  $n = 5$  e  $x = 2$ , de modo que  $\theta|x = 2 \sim Beta(3, 4)$ . Algumas medidas resumo da distribuição posterior para esse exemplo são

- $Moda(\theta|x) = \frac{a+x-1}{a+b+n-2} = \frac{2}{5} = 0,4;$
- $E[\theta|x] = \frac{a+x}{a+b+n} = \frac{3}{7} = 0,43;$



- $Med(\theta|x) \approx \frac{a+x-1/3}{a+b+n-2/3} = \frac{8/3}{19/3} \approx 0,42;$
- $Var(\theta|x) = \frac{(a+x)(b+n-x)}{(a+b+n)^2(a+b+n+1)} = \frac{12}{392} \approx 0,031.$


## 2.4 Distribuição a Priori

- A priori é sempre subjetiva (assim como a escolha do modelo estatístico)!
  - Por exemplo, dizer que os dados seguem uma distribuição normal, é uma escolha subjetiva, muitas vezes baseadas nas facilidades matemáticas que essa distribuição proporciona.
  - Do mesmo modo, suponha que dois indivíduos que consideram que a distribuição do parâmetro é simétrica, com mesmas suposições sobre média e variância. O primeiro pode optar por representar sua distribuição usando uma distribuição Normal, enquanto o segundo pode utilizar uma distribuição T ou Cauchy.
- Não existe “opinião errada”, existem opiniões diferentes, dado o nível de conhecimento e as experiências prévias do indivíduo.
- A priori deve ser sua opinião apenas sobre o parâmetro  $\theta$  e não deve depender de fatores como o desenho do experimento ou o objetivo do estudo.


### 2.4.1 Prioris Baseada na Opinião de um Especialista

#### 2.4.1.1 Método do Histograma

- Muitas vezes, para “extrair” o conhecimento de um especialista, podemos dividir o espaço paramétrico em regiões e pedir para o especialista “ordenar” esses conjuntos, utilizando “pesos” que refletem a crença que o parâmetro esteja em cada uma daquelas regiões.
- **Exemplo 1.** (*Bayesian Computation with R*, Albert, J., pág 27)
  - Seja  $\theta$  uma proporção desconhecida ( $\Theta = [0, 1]$ );
  - Considere a partição  $T = \{[0, 0.1], [0.1, 0.2], \dots, [0.9, 1]\}$ ;
  - Suponha que um especialista atribui pesos  $p = (1, 5.2, 8, 7.2, 4.6, 2.1, 0.7, 0.1, 0, 0)$  a esses intervalos;
  - A priori, nesse caso, é o histograma apresentado a seguir.



- Voltando ao exemplo da moeda, suponha novamente que foram observados  $x = 2$  sucessos em  $n = 5$  lançamentos. A posteriori nesse caso pode ser obtida multiplicando a distribuição a priori pela verossimilhança e “padronizando” a função obtida. Assim:



#### 2.4.1.2 Elicitação de Hiperparâmetros

- Nessa abordagem, a priori é obtida da seguinte maneira:
  1. Escolha uma família de distribuições conveniente. O conceito de “conveniência” aqui pode levar em conta, por exemplo, o suporte da distribuição, se é flexível o suficiente para acomodar diversos tipos de opinião, se permite a obtenção analítica da posteriori e assim por diante;
  2. Obtenha um conjunto de medidas resumo (como média, variância, quantis, etc.);
  3. Utilize as medidas resumo para calcular hiperparâmetros da distribuição escolhida.


- **Exemplo:** Na seção anterior, a priori dada pelo histograma tem média  $m = 0.31$  e variância aproximadamente  $v = 0.02$ . Podemos utilizar como priori, por exemplo, uma distribuição beta com essa média e variância, já que a beta tem um suporte conveniente e facilita as contas, como também já vimos. Assim, vamos considerar uma distribuição  $Beta(a, b)$  e escolher  $a$  e  $b$  satisfazendo:

$$(i) \quad E[\theta] = \frac{a}{a+b} = m \Leftrightarrow b = \left(\frac{1-m}{m}\right)a$$

$$(ii) \quad Var(\theta) = \frac{ab}{(a+b)^2(a+b+1)} = 0.02 \Leftrightarrow a = \frac{m(m-m^2-v)}{v}$$

Resolvendo o sistema temos, de forma geral, que  $a = \frac{m(m-m^2-v)}{v}$  e  $b = \frac{(1-m)(m-m^2-v)}{v}$ .

Assim, no nosso exemplo, teríamos uma  $Beta(3, 6.7)$ . Além disso, já vimos que, nesse caso, a distribuição a posteriori é  $Beta(3+x, 6.7+n-x)$ . Considerando novamente  $n = 5$  e  $x = 2$ , temos:



### 2.4.2 Prioris Conjugadas

Como visto no exemplo da moeda, quando distribuição a priori era  $Beta(a, b)$ , a posteriori era facilmente obtida e também estava na classe das distribuições  $Beta$ . Em particular, quando observa-se  $x$  sucessos em  $n$  realizações de ensaios de Bernoulli, a distribuição a posteriori é  $Beta(a+x, b+n-x)$ . Isso ocorre pois essa distribuição pertence à uma classe bastante específica de distribuições a priori, chamadas distribuições conjugadas.

**Definição** Seja  $\mathcal{P} = \{f(x|\theta) : \theta \in \Theta\}$  uma família de distribuições (condicionais) para  $X$  e considere  $\mathcal{C} = \{h(\theta|a) : a \in A\}$  uma família de distribuições para  $\theta$ . Dizemos que (a família)  $\mathcal{C}$  é **conjugada** para  $\mathcal{P}$  se,  $\forall h(\theta) \in \mathcal{C}$ ,  $h(\theta|x) \propto f(x|\theta)h(\theta) \in \mathcal{C}, \forall x \in \mathfrak{X}$ .

**Resultado 1.** Seja  $X$  v.a. tal que, condicional ao conhecimento de  $\theta$ ,  $X|\theta \sim Bin(n, \theta)$ . Considere que, a priori,  $\theta \sim Beta(a, b)$ . Então,  $\theta|X = x \sim Beta(a+x, b+n-x)$ . Por tanto, a família  $\mathcal{C} = \{Beta(a_1, a_2) : (a_1, a_2) \in \mathbb{R}_+^2\}$  é conjugada para  $\mathcal{P} = \{Bin(n, \theta) : \theta \in [0, 1]\}$ .

• Esse resultado também vale se

1.  $X_1, \dots, X_n$  são v.a.s *condicionalmente independentes e identicamente distribuídas* (c.i.i.d.) com  $X_i|\theta \sim Ber(\theta)$
2.  $X_i|\theta \sim Geo(\theta)$ ,  $i = 1, \dots, n$  c.i.i.d.
3.  $X_i|\theta \sim BinNeg(k, \theta)$   
 $\theta \sim Beta(a, b) \Rightarrow \theta|X = x \sim Beta(a + s, b + f)$  onde  $s$  é o número de sucessos e  $f$  é o número de fracassos.

**Resultado 2.** (*generalização do resultado anterior para o caso onde o número de categorias é maior que 2*)

Seja  $X|\theta \sim Multinomial(n, \theta)$ , isto é, sua função de probabilidade é dada por

$$f(x|\theta) = \binom{n}{x_1, x_2, \dots, x_k} \prod_{i=1}^{k-1} \theta^i \underbrace{\left(1 - \sum_{i=1}^{k-1} \theta_i\right)^{n - \sum_{i=1}^{k-1} x_i}}_{\theta_k^{x_k}}$$

onde  $\theta_i \in [0, 1]$  com  $\sum_{i=1}^K \theta_i = 1$ ,  $x_i \in \{0, 1, \dots, n\}$  com  $\sum_{i=1}^n x_i = n$  e  $\binom{n}{x_1, x_2, \dots, x_k} = \frac{n!}{x_1! x_2! \dots x_k!}$ .

Considere que, a priori,  $\theta \sim Dirichlet(a_1, \dots, a_k)$ ,  $a_i > 0, i = 1, \dots, k$ , isto é, a f.d.p. a priori para  $\theta$  é dada por

$$f(\theta) = \frac{\Gamma(\sum_{i=1}^K a_i)}{\Gamma(a_1)\Gamma(a_2)\dots\Gamma(a_k)} \prod_{i=1}^{k-1} \theta_i^{a_i-1} \underbrace{\left(1 - \sum_{i=1}^{k-1} \theta_i\right)^{a_k-1}}_{\theta_k^{a_k-1}}.$$

Então, a distribuição a posteriori para  $\theta$  é  $\theta|X = x \sim Dirichlet(a_1 + x_1, \dots, a_k + x_k)$ .

**Demo:** Para verificar o resultado, basta ver que

$$f(\theta|x) = \frac{f(x|\theta)f(\theta)}{\int_{\Theta} f(x|\theta)f(\theta)d\theta} \propto f(x|\theta)f(\theta) \propto \prod_{i=1}^{k-1} \theta_i^{(a_i+x_i-1)} \left(1 - \sum_{i=1}^{k-1} \theta_i\right)^{(a_k+x_k)-1}$$

**Resultado 3.** seja  $X_1, \dots, X_n$  v.a. c.i.i.d tais que  $X_i|\theta \sim Unif(0, \theta)$  e considere que, a priori,  $\theta \sim Pareto(a, b)$ . Então  $\theta|X = x \sim Pareto(a + n, \max\{b, x_{(n)}\})$ .

**Demo:**

$$f(x|\theta) \stackrel{ci}{=} \prod_{i=1}^n f(x_i|\theta) \stackrel{id}{=} \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \mathbb{I}_{[0, \theta]}(x_{(n)}) = \frac{1}{\theta^n} \mathbb{I}_{[x_{(n)}, +\infty)}(\theta)$$

onde  $x_{(n)} = \max\{x_1, \dots, x_n\}$ .

$$f(\theta) = \frac{ab^a}{\theta^{a+1}} \mathbb{I}_{[b, +\infty)}(\theta).$$

Então

$$f(\theta|x) \propto f(x|\theta)f(\theta) = \frac{1}{\theta^{a+n+1}} \mathbb{I}_{[x_{(n)}, +\infty)}(\theta) \mathbb{I}_{[b, +\infty)}(\theta) = \frac{1}{\theta^{a+n+1}} \mathbb{I}_{[\max\{b, x_{(n)}\}, +\infty)}(\theta)$$

$\Rightarrow \theta|X = x \sim Pareto(a + n, \max\{b, x_{(n)}\})$ .

**Resultado 4.** Seja  $X_1, \dots, X_n, Y_1, \dots, Y_m$  v.a. condicionalmente independentes tais que  $X_i|\theta \sim \text{Exp}(\theta), i = 1, \dots, n$  e  $Y_j|\theta \sim \text{Poisson}(\theta), j = 1, \dots, m$ . Considere que, a priori,  $\theta \sim \text{Gama}(a, b)$ . Então  $\theta|x, y \sim \text{Gama}(a + n + \sum_j y_j, b + m + \sum_i x_i)$ .

**Demo:**

$$\begin{aligned} f(x, y|\theta) &\stackrel{ci}{=} f(x|\theta)f(y|\theta) \stackrel{ci}{=} \prod_{i=1}^n f(x_i|\theta) \prod_{j=1}^m f(y_j|\theta) = \prod_{i=1}^n \theta e^{-\theta x_i} \prod_{j=1}^m \frac{\theta^{y_j} e^{-\theta}}{y_j!} = \\ &\frac{1}{\prod_{j=1}^m y_j!} \theta^{n+\sum_j y_j} e^{-(m+\sum_i x_i)\theta} \\ f(\theta) &= \frac{b^a}{\Gamma(a)} \theta^{a-1} e^{-b\theta} \\ f(\theta|x, y) &\propto f(x, y|\theta)f(\theta) \propto \theta^{[a+n+\sum_j y_j]-1} e^{-[b+m+\sum_i x_i]\theta} \\ &\Rightarrow \theta|x, y \sim \text{Gama}(a + n + \sum_j y_j, b + m + \sum_i x_i) \end{aligned}$$

**Resultado 5.** Seja  $\mathcal{P} = \{f(x|\theta) : \theta \in \Theta\}$  e  $\mathcal{C} = \{h(\theta|a) : a \in A\}$  uma família conjugada para  $\mathcal{P}$ . Considere  $\mathcal{M} = \{h(\theta) = \sum_{i=1}^m w_i h_i(\theta) : h_i \in \mathcal{C} \text{ e } w_i > 0, \sum_{i=1}^m w_i = 1\}$ . Então  $\mathcal{M}$  é família conjugada para  $\mathcal{P}$ .


**Demo:** Como  $\mathcal{C}$  é conjugada para  $\mathcal{P}$ , para toda função  $h_i \in \mathcal{C}$ , temos que  $f_i(\theta|x) \propto h_i(\theta)f(x|\theta) \in \mathcal{C}$ . Então

$$h \in \mathcal{M} \Rightarrow f(\theta|x) \propto h(\theta)f(x|\theta) \propto \sum_{i=1}^m w_i \underbrace{h_i(\theta)f(x|\theta)}_{\in \mathcal{C}} \propto \sum_{i=1}^m w_i^* f_i(\theta|x) \in \mathcal{M}.$$


**Exemplo.** Seja  $X|\theta \sim \text{Bin}(n, \theta)$  e  $f(\theta) = wf_1(\theta) + (1-w)f_2(\theta)$ , onde  $f_1 \sim \text{Beta}(a_1, b_1)$  e  $f_2 \sim \text{Beta}(a_2, b_2)$ .

$$\begin{aligned} f(\theta|x) &= \frac{f(x|\theta)f(\theta)}{\int_0^1 f(x|\theta)f(\theta)d\theta} = \frac{f(x|\theta)[wf_1(\theta) + (1-w)f_2(\theta)]}{w \int_0^1 f_1(\theta)f(x|\theta)d\theta + (1-w) \int_0^1 f_2(\theta)d\theta} \\ &\propto \frac{w \binom{n}{x} \frac{\Gamma(a_1+b_1)}{\Gamma(a_1)\Gamma(b_1)} \theta^{a_1+x-1} (1-\theta)^{b_1+n-x-1} + (1-w) \binom{n}{x} \frac{\Gamma(a_2+b_2)}{\Gamma(a_2)\Gamma(b_2)} \theta^{a_2+x-1} (1-\theta)^{b_2+n-x-1}}{\underbrace{w \binom{n}{x} \frac{\Gamma(a_1+b_1)}{\Gamma(a_1)\Gamma(b_1)} \frac{\Gamma(a_1+x)\Gamma(b_1+n-x)}{\Gamma(a_1+b_1+n)}}_A + \underbrace{(1-w) \binom{n}{x} \frac{\Gamma(a_2+b_2)}{\Gamma(a_2)\Gamma(b_2)} \frac{\Gamma(a_2+x)\Gamma(b_2+n-x)}{\Gamma(a_2+b_2+n)}}_B} \\ &\propto \underbrace{\frac{A}{A+B}}_{w^*} \text{Beta}(a_1+x, b_1+n-x) + \underbrace{\frac{B}{A+B}}_{1-w^*} \text{Beta}(a_2+x, b_2+n-x) \end{aligned}$$

Primeiramente, suponha que  $n = 5$ , e temos uma mistura das distribuições  $\text{Beta}(5, 12)$  e  $\text{Beta}(10, 3)$ , com  $w = 0.5$ . O gráfico a seguir apresenta as distribuições a priori, a verossimilhança e a posteriori para cada possível valor de  $x$  em  $\{0, 1, \dots, 5\}$ .



Agora, suponha que  $n = 5$  e foi observado  $x = 2$ . Novamente, considere a mistura das distribuições  $Beta(5, 12)$  e  $Beta(10, 3)$  mas agora com pesos  $w$  variando no conjunto  $\{0, 0.1, \dots, 0.9, 1\}$ .



## Capítulo 3

# Apendice: Breve Resumo de Medida e Probabilidade

### 3.1 Breve Resumo de Medida e Probabilidade

- $\Omega$ : espaço amostral (um conjunto não vazio).
- $\mathcal{A}$ :  $\sigma$ -álgebra de subconjuntos de  $\Omega$ , isto é,
  1.  $\Omega \in \mathcal{A}$ ;
  2.  $A \in \mathcal{A} \implies A^c \in \mathcal{A}$ ;
  3.  $A_1, A_2, \dots \in \mathcal{A} \implies \bigcup_{i \geq 1} A_i \in \mathcal{A}$ .
- Os elementos de  $\mathcal{A}$  são chamados de *eventos* e serão denotados por  $A, B, C, \dots, A_1, A_2, \dots$
- $(\Omega, \mathcal{A})$ : *espaço mensurável*.
- Usualmente, denota-se a  $\sigma$ -álgebra gerada por um conjunto  $\mathcal{C}$  como  $\sigma(\mathcal{C})$ . Por exemplo:
  - $\sigma(\Omega) = \{\emptyset, \Omega\}$  ( $\sigma$ -álgebra trivial);
  - Para  $A \subset \Omega$ ,  $\sigma(A) = \{\emptyset, A, A^c, \Omega\}$ ;
  - $\sigma(\mathbb{N}) = \mathcal{P}(\mathbb{N})$  (partes de  $\mathbb{N}$ , todos o subconjuntos de  $\mathbb{N}$ );
  - $\sigma(\{(-\infty, x) : x \in \mathbb{R}\}) = \mathcal{B}(\mathbb{R})$  (borelianos de  $\mathbb{R}$ )
- $\mu : \mathcal{A} \longrightarrow \bar{\mathbb{R}}_+$  é uma *medida* se
  1.  $\mu(\emptyset) = 0$ ;
  2.  $A_1, A_2, \dots \in \mathcal{A}$  com  $A_i \cap A_j = \emptyset, \forall i \neq j$ ,  $\mu\left(\bigcup_{i \geq 1} A_i\right) = \sum_{i \geq 1} \mu(A_i)$ .
- $(\Omega, \mathcal{A}, \mu)$  é chamado de *espaço de medida*.

**Exemplo 1 (medida de contagem):** Seja  $\Omega$  um conjunto não vazio e  $A \subseteq \Omega$ . Defina  $\mu(A) = |A|$  como o número de elementos (cardinalidade) de  $A$ . Assim,  $\mu(\Omega) > 0$ ,  $\mu(\emptyset) = 0$  e, se  $(A_n)_{n \geq 1}$  é uma sequência de eventos disjuntos, então  $\mu(\cup A_n) = \sum \mu(A_n)$ . Note que  $\mu(A) = \infty$  é possível se  $\Omega$  tem infinitos elementos.

**Exemplo 2 (medida de Lebesgue):** Seja  $\Omega = \mathbb{R}$  e  $A \subseteq \Omega$  um intervalo. Se  $A$  é limitado, defina  $\mu(A)$  como o comprimento do intervalo  $A$ . Se  $A$  não é limitado,  $\mu(A) = \infty$ . Note que  $\mu(\mathbb{R}) = \infty$ ,  $\mu(\emptyset) = 0$  e, se  $A_1 \cap A_2 = \emptyset$  e  $A_1 \cup A_2$  é um intervalo (ou uma união de intervalos disjuntos), então  $\mu(A_1 \cup A_2) = \mu(A_1) + \mu(A_2)$ .

**Exemplo 3:** Seja  $f : \mathbb{R} \rightarrow \mathbb{R}_+$  uma função contínua e não nula. Para cada intervalo  $A$ , defina  $\mu(A) = \int_A f(x)dx = \int_{\mathbb{R}} \mathbb{I}_A(x)f(x)dx$ . Então,  $\mu(\mathbb{R}) > 0$ ,  $\mu(\emptyset) = 0$  e, se  $A_1 \cap A_2 = \emptyset$  e  $A_1 \cup A_2$  é um intervalo (ou uma união de intervalos disjuntos), então  $\mu(A_1 \cup A_2) = \mu(A_1) + \mu(A_2)$ .

**Definição:** Seja  $(\Omega, \mathcal{A})$  um espaço mensurável e  $\mu_1$  e  $\mu_2$  medidas nesse espaço. Dizemos que  $\mu_2$  é *absolutamente contínua* com relação à  $\mu_1$  se,  $\forall A \in \mathcal{A}$ ,  $\mu_1(A) = 0 \Rightarrow \mu_2(A) = 0$ .

Nesse caso, dizemos que  $\mu_2$  é dominada por  $\mu_1$  ou que  $\mu_1$  é uma medida dominante para  $\mu_2$  e denotamos  $\mu_2 \ll \mu_1$ .

**Teorema (de Radon-Nikodin):** Seja  $\mu_2 \ll \mu_1$  com  $\mu_1$   $\sigma$ -finita. Então,  $\exists f : \Omega \rightarrow [0, +\infty]$  tal que,  $\forall A \in \mathcal{A}$ ,

$$\mu_2(A) = \int_A f(x)d\mu_1(x).$$

Além disso, se  $g : \Omega \rightarrow \mathbb{R}$  é  $\mu_2$ -integrável, então

$$\int g(x)d\mu_2(x) = \int g(x)f(x)d\mu_1(x).$$

A função  $f = \frac{d\mu_2}{d\mu_1}$  é chamada de derivada de Radon-Nikodin da medida  $\mu_2$  com relação à medida  $\mu_1$  e é única  $\mu_1$ -q.c.

- $P : \mathcal{A} \rightarrow [0, 1]$  é uma *medida de probabilidade* se
  1.  $P(\Omega) = 1$ ;
  2.  $A_1, A_2, \dots \in \mathcal{A}$  com  $A_i \cap A_j = \emptyset$ ,  $P\left(\bigcup_{i \geq 1} A_i\right) = \sum_{i \geq 1} P(A_i)$ .
- $(\Omega, \mathcal{A}, P)$ : espaço de probabilidade
- Seja  $(\Omega, \mathcal{A})$  e  $(\mathfrak{X}, \mathcal{F})$  dois espaços mensuráveis. Se  $X : \Omega \rightarrow \mathfrak{X}$  é chamado de *quantidade aleatória* se uma função mensurável, isto é, se  $\forall B \in \mathcal{F}$ ,  $A = X^{-1}(B) \in \mathcal{A}$ . Se  $\mathfrak{X} = \mathbb{R}$  e  $\mathcal{F} = \mathcal{B}$  ( $\sigma$ -álgebra de Borel),  $X$  é chamado *variável aleatória*.
- A medida de probabilidade induzida por  $X$  recebe o nome de *distribuição de  $X$* :

$$P_X(B) = P(\{\omega \in \Omega : X(\omega) \in B\})$$

**Exemplo 1:** Seja  $\Omega = \mathfrak{X} = \mathbb{R}$  com a  $\sigma$ -álgebra de Borel e  $f$  uma função não negativa tal que  $\int f(x)dx = 1$ . Defina  $\mu(A) = \int_A f(x)dx$  e  $X(\omega) = \omega$ . Então,  $X$  é uma variável aleatória contínua com função de densidade de probabilidade (f.d.p.)  $f$  e  $\mu_x = \mu$ . Além disso,  $\mu_X$  é absolutamente contínua com relação à medida de Lebesgue ( $\mu_X \ll \lambda$ ) e  $\frac{d\mu_X}{d\lambda} = f$ .



**Exemplo 2:** Seja  $\Omega = \mathbb{R}$  com a  $\sigma$ -álgebra de Borel,  $\mathfrak{X} = \{x_1, x_2, \dots\}$  um conjunto enumerável. Seja  $f$  uma função não negativa definida em  $\mathfrak{X}$  tal que  $\sum_{i=1}^{\infty} f(x_i) = 1$ . Defina  $\mu(A) = \sum_{\{i: x_i \in A\}} f(x_i)$ . Então  $X$  é uma variável aleatória discreta com função de probabilidade (f.d.p.)  $f$  e  $\mu_X = \mu$ . Além disso,  $\mu_X$  é absolutamente contínua com relação à medida de contagem ( $\mu_X \ll \nu$ ) e  $\frac{d\mu_X}{d\nu} = f$ .


### 3.2 Valor Esperado de $X$ (OU uma ideia da tal Integral de Lebesgue)

Por simplicidade, considere  $(\Omega = [0, 1], \mathcal{A} = \mathcal{B}([0, 1]), P = \lambda)$ .

Considere uma variável aleatória discreta  $X : \Omega \rightarrow \mathbb{R}$ , assumindo valores em  $\mathfrak{X} = \{x_1, x_2, \dots, x_k\}$  com probabilidades  $\{p_1, p_2, \dots, p_k\}$  com  $x_i \geq 0, \forall i$ . Já vimos que o *valor esperado* (ou *esperança*) de  $X$  é  $E[X] = \sum x_i P(X = x_i) = \sum x_i p_i$ .

Podemos definir essa v.a. como

$$X(\omega) = \begin{cases} x_1, & 0 \leq \omega \leq p_1 \\ x_2, & p_1 < \omega \leq p_1 + p_2 \\ \vdots & \\ x_j, & \sum_{i=1}^{j-1} p_i < \omega \leq \sum_{i=1}^j p_i \\ \vdots & \\ x_k, & 1 - p_k < \omega \leq 1 \end{cases}$$



Assim, temos que

- $P_X(X = x_1) = P(\{\omega \in \Omega : X(\omega) = x_1\}) = \lambda([0, p_1]) = p_1,$
- $P_X(X = x_j) = P(\{\omega \in \Omega : X(\omega) = x_j\}) = \lambda\left(\left[\sum_{i=1}^{j-1} p_i, \sum_{i=1}^j p_i\right]\right) = p_j, \quad j \in \{2, \dots, k\}.$

**Definição:** Uma função mensurável (v.a.)  $X : \Omega \longrightarrow \mathbb{R}_+$  é dita *simples* se assumir um número finito de valores.

**Definição:** Considere  $(\Omega, \mathcal{A}, P)$ ,  $X : \Omega \longrightarrow \mathbb{R}_+$  v.a. assumindo valores  $\{x_1, x_2, \dots, x_k\}$  e  $A_1, A_2, \dots, A_k$  eventos disjuntos em  $\mathcal{A}$ . Seja  $X(\omega) = \sum_{i=1}^k x_i \mathbb{I}_{A_i}(\omega)$ , uma função simples com  $A_i = X^{-1}(x_i)$ ,  $i = 1, \dots, k$ . A *integral de Lebesgue* de  $X$  em relação à medida  $P$  é

$$E[X] = \int_{\Omega} X dP = \sum_{i=1}^k x_i P(A_i).$$

### 3.3 Propriedades da integral (*de Lebesgue*) de $X$ (v.a) em relação a $P$

**P1.**  $\int_{\Omega} X dP \geq 0,$

**P2.**  $\int_{\Omega} cX dP = c \int_{\Omega} X dP.$

**P3.**  $\int_{\Omega} (X+Y) dP = \int_{\Omega} X dP + \int_{\Omega} Y dP$

**Demo (P1):** Segue de  $x_i \geq 0$  e  $P(A_i) \geq 0$ .

**Demo (P2):**

Para  $X$  v.a. temos

$$X = \sum_{i=1}^k x_i \mathbb{I}_{A_i} \text{ e } cX \text{ (também v.a.)}$$

$$cX = \sum_{i=1}^k (cx_i) \mathbb{I}_{A_i}, \text{ logo}$$

$$\int_{\Omega} cX dP = \sum_{i=1}^k (cx_i) P(A_i) = c \sum_{i=1}^k x_i P(A_i) = c \int_{\Omega} X dP$$

**Demo (P3):**

$$X = \sum_{i=1}^k x_i \mathbb{I}_{A_i} \text{ e } Y = \sum_{j=1}^l y_j \mathbb{I}_{B_j}.$$

$$\begin{aligned} X + Y &= \sum_{i=1}^k x_i \mathbb{I}_{A_i} + \sum_{j=1}^l y_j \mathbb{I}_{B_j} \\ &= \sum_{i=1}^k \sum_{j=1}^l x_i \mathbb{I}_{A_i \cap B_j} + \sum_{i=1}^k \sum_{j=1}^l y_j \mathbb{I}_{A_i \cap B_j} \end{aligned}$$

$$\implies X + Y = \sum_{i=1}^k \sum_{j=1}^l (x_i + y_j) \mathbb{I}_{A_i \cap B_j}.$$

$$\begin{aligned} \int_{\Omega} (X + Y) dP &= \sum_{i=1}^k \sum_{j=1}^l (x_i + y_j) P(A_i \cap B_j) \\ &= \sum_{i=1}^k \sum_{j=1}^l (x_i) P(A_i \cap B_j) + \sum_{i=1}^k \sum_{j=1}^l (y_j) P(A_i \cap B_j) \\ &= \sum_{i=1}^k x_i P(A_i) + \sum_{j=1}^l y_j P(B_j) \\ &= \int_{\Omega} X dP + \int_{\Omega} Y dP. \end{aligned}$$

Seja  $X : \Omega \rightarrow \mathbb{R}$  uma função mensurável não negativa e considere o conjunto de funções  $\mathcal{C}_X = \{f : \Omega \rightarrow \mathbb{R}_+, f \text{ simples}, f \leq X\}$ .

**(INCLUIR GRÁFICOS DE f1 e f2)**

Definimos, nesse caso, o *valor esperado de  $X$*  por

$$E[X] = \int_{\Omega} X dP = \sup\{\int_{\Omega} f dP : f \in \mathcal{C}_X\}.$$

**Resultado**

$X, Y : \Omega \rightarrow \mathbb{R}_+$ , com  $X \leq Y$ . Então  $E[X] \leq E[Y]$ .

**Demo:** Como  $X \leq Y$  (isto é,  $X(w) \leq Y(w) \forall w \in \Omega$ ),  $\mathcal{C}_X \subseteq \mathcal{C}_Y$   
 $\Rightarrow \sup\{\int_{\Omega} f dP : f \in \mathcal{C}_X\} \leq \sup\{\int_{\Omega} f dP : f \in \mathcal{C}_Y\} \Rightarrow \int_{\Omega} X dP \leq \int_{\Omega} Y dP$ .

**Definição:** Seja  $X : \Omega \rightarrow \mathbb{R}_+$  e  $E \in \mathcal{A}$  definimos  $E(X \mathbb{I}_E) = \int_E X dP = \int_{\Omega} X \mathbb{I}_E dP$ . Se  $E, F \in \mathcal{A}$  com  $E \subseteq F$ ,  $\int_E X dP \leq \int_F X dP$ .

**Resultado:** Para toda função  $X : \Omega \rightarrow \mathbb{R}_+$ , existe uma sequência  $(f_n)_{n \geq 1}$  de funções simples não-negativas tais que  $f_n(w) \leq f_{n+1}(w)$ ,  $\forall w \in \Omega$ ,  $\forall n \in \mathbb{N}$  com  $f_n(w) \uparrow X(w)$ ,  $\forall w \in \Omega$ .

**Exemplo** de sequência  $(f_n)_{n \geq 1}$  atendendo as condições anteriores

Para cada  $n$ , considere  $1 + n2^n$  conjuntos em  $\mathcal{A}$ :

- $E_j^n = \left\{w \in \Omega : \frac{j}{2^n} \leq X(w) \leq \frac{j+1}{2^n}\right\}$ ,  $j = 0, 1, \dots, n2^n - 1$ .
- $E_{n2^n}^n = \{w \in \Omega : X(w) \geq n\}$

e defina  $X_n(w) = \sum_{j=0}^{n2^n} \frac{j}{2^n} \mathbb{I}_{E_j^n}(w)$ . Pode-se provar que  $(X_n)_{n \geq 1}$  é tal que

- $X_n$  é simples,  $\forall n \geq 1$
- $X_n \leq X_{n+1}$
- $X_n(w) \uparrow X(w)$

**(INCLUIR GRÁFICOS DA CONVERGÊNCIA)**

**Propriedades:** Se  $X, Y : \Omega \rightarrow \mathbb{R}_+$  são funções mensuráveis (v.a.) então

$$(1) \int_{\Omega} cX dP = c \int_{\Omega} X dP, c \geq 0$$

$$(2) \int_{\Omega} (X + Y) dP = \int_{\Omega} X dP + \int_{\Omega} Y dP$$

**Demo (1)** Seja  $X_n \uparrow X$ ,  $X_n \geq 0$  simples. Então  $cX_n \uparrow cX$ ,  $cX_n \geq 0$ , simples.

$$\begin{aligned} \int_{\Omega} cXdP &= \lim_{n \rightarrow \infty} \int_{\Omega} cX_n dP \\ &= \lim_{n \rightarrow \infty} c \int_{\Omega} X_n dP \\ &= c \lim_{n \rightarrow \infty} \int_{\Omega} X_n dP \\ &= c \int_{\Omega} X dP. \end{aligned}$$

**Demo (2)** Exercício.

**Exemplo:** Suponha que  $X$  assume valores em  $\mathbb{N}$ . Pode-se escrever  $X = \sum_{i=1}^{\infty} i \mathbb{I}_{A_i}$ , com  $A_i = x^{-1}(\{i\})$ .

Defina  $X_n = \sum_{i=1}^{n-1} i \mathbb{I}_{A_i} + n \mathbb{I}_{\bigcup_{j=n}^{\infty} A_j}$ . Então  $X_n$  é simples,  $X_n \geq 0$ ,  $X_n \leq X_{n+1}$  e  $X_n \uparrow X$ , de modo que  $E(X) = \int_{\Omega} X dP = \lim_{n \rightarrow \infty} \int_{\Omega} X_n dP$ . Além disso,

$$\begin{aligned} \int_{\Omega} X_n dP &= \sum_{i=1}^{n-1} iP(A_i) + nP\left(\bigcup_{j=n}^{\infty} A_j\right) \\ &= \sum_{i=1}^{n-1} iP(X=i) + nP(X \geq n) \\ &= \sum_{i=1}^{n-1} \sum_{j=1}^i P(X=i) + nP(X \geq n) \\ &= \sum_{j=1}^{n-1} \sum_{i=j}^{n-1} P(X=i) + nP(X \geq n) \\ &= \sum_{j=1}^{n-1} P(j \leq X \leq n-1) + nP(X \geq n) \\ &= \sum_{j=1}^n P(X \geq j), \end{aligned}$$

$$\text{então, } E(X) = \lim_{n \rightarrow \infty} \sum_{j=1}^n P(X \geq j) = \sum_{j=1}^{\infty} P(X \geq j).$$

Seja  $X : \Omega \rightarrow \mathbb{R}$  e  $X^-, X^+ : \Omega \rightarrow \mathbb{R}$  dados por

- $X^- = \max\{-X, 0\}$  (parte negativa de  $X$ ) e
- $X^+ = \max\{X, 0\}$  (parte positiva de  $X$ )

(INCLUIR GRÁFICO DAS PARTES POSITIVAS E NEGATIVAS DE X)

Note que  $X = X^+ - X^-$

Se  $\int_{\Omega} X^+ dP < \infty$  ou  $\int_{\Omega} X^- dP < \infty$ , definimos

$$E(X) = \int_{\Omega} X dP = \int_{\Omega} X^+ dP - \int_{\Omega} X^- dP = E(X^+) - E(X^-).$$

Além disso, seja  $|X| = X^+ + X^-$ . Então  $E[|X|] < \infty$  se  $E(X^+) < \infty$  e  $E(X^-) < \infty$ , e, nesse caso, dizemos que  $X$  é *integrável*.

**Propriedades:**

$$(1) \quad X \leq Y \Rightarrow E(X) \leq E(Y) \quad \text{Demo: } X \leq Y \Rightarrow \begin{cases} X^+ \leq Y^+ \\ X^- \geq Y^- \end{cases}$$

$$E(X) = E(X^+) - E(X^-) \leq E(Y^+) - E(Y^-) = E(Y).$$

(2)  $c \in \mathbb{R}$ ,  $E(cX) = cE(X)$

$$> \textbf{Demo: } (cX)^+ = \begin{cases} cX^+, & c \geq 0 \\ (-c)X^-, & c < 0 \end{cases}$$

$$(cX)^- = \begin{cases} cX^-, & c \geq 0 \\ (-c)X^+, & c < 0 \end{cases}$$

$$\text{Para } c < 0, E[cX] = E[(X)^+] - E[(cX)] = E[(-c)X^-] - E[(-c)X^+] = (-c)E[X^-] + cE[X^+] = cE[X].$$

(3)  $X, Y$  integráveis.  $E(X + Y) = E(X) + E(Y)$ .

$$> \textbf{Demo: } \int_{\Omega} X^+ + Y^+ dP < \infty \text{ ou } \int_{\Omega} X^- + Y^- dP < \infty$$

$$X + Y = (X + Y)^+ - (X + Y)^- = X^+ - X^- + Y^+ - Y^-$$

$$\Rightarrow (X + Y)^+ + X^- + Y^- = X^+ + Y^+ + (X + Y)^-$$

$$\Rightarrow \int_{\Omega} (X + Y)^+ dP + \int_{\Omega} X^- dP + \int_{\Omega} Y^- dP$$

$$= \int_{\Omega} X^+ dP + \int_{\Omega} Y^+ dP + \int_{\Omega} (X + Y)^- dP.$$

$$|X + Y| = |X^+ - X^- + Y^+ - Y^-| \leq X^+ + X^- + Y^+ + Y^-$$

$$\Rightarrow \underbrace{\int_{\Omega} (X + Y)^+ dP - \int_{\Omega} (X + Y)^- dP}_{\int_{\Omega} (X + Y) dP} = \underbrace{\int_{\Omega} X^+ dP - \int_{\Omega} X^- dP}_{\int_{\Omega} X dP} + \underbrace{\int_{\Omega} Y^+ dP - \int_{\Omega} Y^- dP}_{\int_{\Omega} Y dP}.$$

### 3.4 Funções de Variáveis Aleatórias

Considere agora uma v.a.  $X : \Omega \rightarrow \mathbb{R}$  e uma função real  $g : \mathbb{R} \rightarrow \mathbb{R}$ . Defina  $Y = g(X)$ . Então

$$(\Omega, \mathcal{A}, P) \xrightarrow{X} (\mathbb{R}, \mathcal{B}(\mathbb{R}), P_X) \xrightarrow{g} (\mathbb{R}, \mathcal{B}(\mathbb{R}), P_Y)$$

$$(\Omega, \mathcal{A}, P) \xrightarrow{Y=g(X)} (\mathbb{R}, \mathcal{B}(\mathbb{R}), P_Y)$$

Logo, se  $g$  é uma função mensurável,  $Y = g(X)$  também é v.a. e as medidas induzidas por  $X$  e  $Y$  são

$$P_X(A) = P(X^{-1}(A)) = P(\{w \in \Omega : X(w) \in A\})$$

$$P_Y(B) = P_X(g^{-1}(B)) = P_X(\{x \in \mathbb{R} : g(x) \in B\}) = P(\{w \in \Omega : g(X(w)) \in B\}).$$

Assim, uma pergunta natural é como obter o valor esperado de  $Y$ .

$$E(Y) = \int_{\Omega} Y dP = \int_{\Omega} g(X) dP \stackrel{?}{=} \int_{\mathbb{R}} g dP_X.$$

(1) Seja  $g$  simples  $g = \sum_{i=1}^k g_i \mathbb{I}_{B_i}$ ,  $g_1, \dots, g_k \in \mathbb{R}$  e  $B_1, \dots, B_k \in \mathcal{B}(\mathbb{R})$

$$\begin{aligned} \int_{\Omega} Y dP &= \int_{\Omega} g(x) dP = \int_{\Omega} \left( \sum_{i=1}^k g_i \mathbb{I}_{B_i}(x) \right) dP = \int_{\Omega} \left( \sum_{i=1}^k g_i \mathbb{I}_{X^{-1}(B_i)} \right) dP \stackrel{def}{=} \sum_{i=1}^k g_i P(X^{-1}(B_i)) = \\ &= \sum_{i=1}^k g_i P_X(B_i) = \int_{\mathbb{R}} \left( \sum_{i=1}^k g_i \mathbb{I}_{B_i} \right) dP = \int_{\mathbb{R}} g dP_X. \end{aligned}$$

(2) Seja  $g$  não negativa  $g \geq 0$ , e  $(g_n)_{n \geq 1}$ ,  $g_n \geq 0$  simples tal que  $g_n \uparrow g$ . Como  $g_n$  é simples:

$$\int_{\Omega} g_n(x) dP = \int_{\mathbb{R}} g_n dP_X \xrightarrow{\text{limite}} \int_{\Omega} g(x) dP = \int_{\mathbb{R}} g dP_X.$$

(3) Agora  $g : \mathbb{R} \rightarrow \mathbb{R}$ .

$$\int_{\Omega} g^+(x) dP = \int_{\mathbb{R}} g^+ dP_X,$$

$$\int_{\Omega} g^-(x) dP = \int_{\mathbb{R}} g^- dP_X,$$

$$\text{logo, } \int_{\Omega} g(x) dP = \int_{\mathbb{R}} g dP_X.$$

Suponha agora  $X$  v.a. discreta assumindo valores em  $\{x_1, x_2, \dots\}$  com probabilidade 1.

$$P(X \in A) = \sum_{i: x_i \in A} P(X = x_i)$$

Vamos “verificar” que  $E[g(X)] = \sum_{i=1}^{\infty} g(x_i) P(X = x_i)$

(1)  $g$  simples

$$g = \sum_{i=1}^k g_i \mathbb{I}_{B_i}, \quad g_1, \dots, g_k \in \mathbb{R} \quad B_1, \dots, B_k \in \mathcal{B}(\mathbb{R})$$

$$\begin{aligned} E[g(X)] &= \dots \sum_{i=1}^k g_i P(X \in B_i) = \sum_{i=1}^k g_i \sum_{j: x_j \in B_i} P(X = x_j) = \sum_{i=1}^k g_i \sum_{j=1}^{\infty} \mathbb{I}_{B_i}(x_j) P(X = x_j) = \\ &= \sum_{j=1}^{\infty} \underbrace{\left( \sum_{i=1}^k g_i \mathbb{I}_{B_i}(x_j) \right)}_{g(x_j)} P(X = x_j). \end{aligned}$$

(2)  $g \geq 0, g_n \geq 0, g_n$  simples tal que  $g_n \uparrow g$

$$\int_{\Omega} g(X) dP = \lim_{n \rightarrow \infty} \int_{\Omega} g_n(X) dP = \lim_{n \rightarrow \infty} \left\{ \sum_{j=1}^{\infty} g_n(x_j) P(X = x_j) \right\} = \sum_{j=1}^{\infty} g(x_j) P(X = x_j)$$

Suponha agora  $X$  v.a. absolutamente contínua com densidade  $f_X$ ,

$$P(X \in A) = \int_A f_X(t) dt.$$

Assim, em geral, vale que:

$X$  discreto:  $E[g(X)] = \sum_{j=1}^{\infty} g(x_j) P(X = x_j)$  e se

$X$  contínua (absolutamente):  $E[g(X)] = \int_{\mathbb{R}} g(x) f_X(x) dx$

Esses resultados valem também se  $X : \Omega \rightarrow \mathbb{R}^k$  e  $g : \mathbb{R}^k \rightarrow \mathbb{R}$ .

### Exemplos

1.  $X \sim \text{Poisson}(\lambda)$

$$E[X] = \sum_{x=0}^{\infty} x P(X = x) = \sum_{x=0}^{\infty} x \frac{e^{-\lambda} \lambda^x}{x!} = \sum_{x=1}^{\infty} \frac{e^{-\lambda} \lambda^x}{(x-1)!} \lambda \sum_{x=1}^{\infty} \frac{e^{-\lambda} \lambda^{x-1}}{(x-1)!} \Rightarrow E(X) = \lambda.$$

2. Ainda no Exemplo, considere  $g(\mu) = e^{\mu}$

$$\begin{aligned} E[g(X)] &= \sum_{x=0}^{\infty} g(x) P(X = x) = \sum_{x=0}^{\infty} e^x \frac{e^{-\lambda} \lambda^x}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e)^x}{x!} = e^{-\lambda} e^{\lambda e} \underbrace{\sum_{x=0}^{\infty} \frac{e^{-\lambda e} (\lambda e)^x}{x!}}_1 = \\ &= e^{\lambda e - \lambda} = e^{\lambda(e-1)}. \end{aligned}$$

3.  $X \sim \text{Beta}(a, b)$   $E[g(X)]$ .  $g(x) = x^n (1-x)^m$

$$\begin{aligned} E[X] &= \int_{-\infty}^{\infty} x f_X(x) dx = \int_0^1 x \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} dx = \frac{\Gamma(a+1)\Gamma(b)}{\Gamma(a+1+b)} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \int_0^1 \frac{\Gamma(a+1+b)}{\Gamma(a+1)\Gamma(b)} x^{(a+1)-1} (1-x)^{(b-1)-1} dx \\ &= \frac{\Gamma(a+1)\Gamma(b)}{\Gamma(a+1+b)} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \end{aligned}$$

**Definição:** Uma função  $F : \mathbb{R} \rightarrow [0, 1]$  é uma função de distribuição (f.d.) se

- (i)  $F$  é não-decrescente e contínua à direita;
- (ii)  $\lim_{x \downarrow -\infty} F(x) = 0$  e  $\lim_{x \uparrow +\infty} F(x) = 1$

**Proposição:** Se  $X$  é uma v.a., então  $F_X(x) = P_X(X \leq x)$  é uma f.d. Reciprocamente, se  $F_X$  é uma f.d, então existe uma v.a.  $X$  com f.d.  $F_X$ .

- Podemos usar uma f.d.  $F$  para criar uma medida em  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ . Defina  $P((a, b]) = F(b) - F(a)$  e extenda essa medida para a  $\sigma$ -álgebra usando o teorema de extensão de Caratheodory.
- Reciprocamente, se  $P$  é uma medida de probabilidade em  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  então  $F(x) = P((-\infty, x])$  é uma f.d.
- $f : \mathbb{R} \rightarrow \mathbb{R}$  mensurável,  $\int f(x)dF(x) = \int f(x)dP(x)$
- Se  $P$  é uma probabilidade em  $(\mathbb{R}^k, \mathcal{B}(\mathbb{R}^k))$  então uma f.d. conjunta pode ser definida por  $F(x_1, \dots, x_k) = P((-\infty, x_1] \times \dots \times (-\infty, x_k])$ , f.d. conjunta do vector aleatório  $X = (X_1, \dots, X_K)$ .

**Definição:**  $(\Omega, \mathcal{A}, P)$  espaço de probabilidade e  $(\mathfrak{X}, \mathfrak{F}, \mathcal{V})$  espaço mensurável. Considere  $X : \Omega \rightarrow \mathfrak{X}$  uma v.a. e  $P_X$  a medida induzida por  $X$  de  $P$ , i.e.  $P_X(B) = P(X^{-1}(B))$ . Suponha que  $P_X \ll \mathcal{V}$ . Então, a derivada de Radon-Nicodin  $f_X = \frac{dP_X}{d\mathcal{V}}$  é a densidade de  $X$  com respeito a  $\mathcal{V}$ .

**Proposição:** Se  $h : \mathfrak{X} \rightarrow \mathbb{R}$  é mensurável e  $f_X = \frac{dP_X}{d\mathcal{V}}$ , então  $\int h(x)dF_X(x) = \int h(x)f_X(x)d\mathcal{V}$ .

## 3.5 Aula 6

### Exemplos (continuação)

4.  $X \sim Geo(\theta)$

$P(X = x) = (1 - \theta)^{x-1}\theta \mathbb{I}_{\{1,2,\dots\}}(x)$  como  $X$  é inteira não-negativa, vale que:

$$E(X) = \sum_{i=1}^{\infty} P(X \geq i) = \sum_{i=1}^{\infty} \left\{ \sum_{j=i}^{\infty} P(X = j) \right\} = \sum_{i=1}^{\infty} \left\{ \sum_{j=i}^{\infty} (1 - \theta)^{j-1}\theta \right\} = \sum_{i=1}^{\infty} (1 - \theta)^{i-1} \Rightarrow E(X) = \frac{1}{\theta}$$

Se  $X$  é contínua não-negativa, então

$$E(X) = \int_0^{\infty} P(X > t)dt.$$

#### Exemplo

$X \sim Exp(\lambda)$

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{I}_{\mathbb{R}_+}(x)$$

$$P(X > t) = \int_t^{\infty} \lambda e^{-\lambda s} ds = e^{-\lambda t}$$

$$\text{Assim, } E(X) = \int_0^{\infty} P(X > t)dt = \frac{1}{\lambda} \underbrace{\int_0^{\infty} \lambda e^{-\lambda t} dt}_1 \Rightarrow E(X) = \frac{1}{\lambda}$$

5.  $(X, Y)$  absolutamente contínuo com densidade

$$f(x, y) = \frac{1}{y} e^{-y} \mathbb{I}_{(0, y)}(x) \mathbb{I}_{\mathbb{R}_+}(y); g(x, y) = xy$$

$$E(g(X, Y)) = ?$$

$$E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f(x, y) dx dy = \int_{-\infty}^{\infty} \left[ \int_{-\infty}^{\infty} xy \frac{1}{y} e^{-y} dx \right] dy = \int_0^{\infty} \frac{y^2}{2} e^{-y} dy = \frac{1}{2} \frac{\Gamma(3)}{1^3} \int_0^{\infty} \frac{1^3}{\Gamma(3)} y^2 e^{-y} dy \Rightarrow E(XY) = 1$$

6.  $(X_1, \dots, X_k) \sim \text{DIR}(a_1, \dots, a_k)$

$$g(X_1, \dots, X_k) = X_1^{n_1} X_2^{n_2} \dots X_k^{n_k} (1 - X_1 - \dots - X_k)^{n_0}$$

$$E[g(X_1, \dots, X_k)] = \int_{S_k} X_1^{n_1} \dots X_k^{n_k} (1 - X_1 - \dots - X_k)^{n_0} \underbrace{\frac{\Gamma(a_0 + a_1 + \dots + a_k)}{\Gamma(a_0)\Gamma(a_1)\dots\Gamma(a_k)}}_{c(a_0, a_1, \dots, a_k)} x_1^{a_1-1} x_2^{a_2-1} \dots x_k^{a_k-1} (1 -$$

$$x_1 - \dots - x_k)^{a_0-1} dx,$$

$$\text{onde } S_k = \{(y_1, y_2, \dots, y_k) \in \mathbb{R}_+^K : y_1 + \dots + y_k \leq 1\}$$

$$\text{Então, } E[g(y_1, \dots, y_k)] = c(a_0, a_1, \dots, a_k) \int_{S_K} x_1^{a_1+n_1-1} \dots x_k^{a_k+n_k-1} (1 - x_1 - \dots - x_k)^{a_0+n_0-1} dx$$

$$\Rightarrow E[g(x_1, \dots, x_k)] = \frac{c(a_0, \dots, a_k)}{c(a_0 + n_0, a_1 + n_1, \dots, a_k + n_k)}$$

7.  $n$  lançamentos de uma moeda. Dizemos que ocorre um “rum” de tamanho  $k$  se são observadas  $k$  caras consecutivas.

$X$ : Número de lançamentos de “rum” de tamanho  $k$  observados.

$$n = 4 \text{ } cc\bar{c}\bar{c}$$

$$k = 2 \text{ } ccc\bar{c}$$

Definimos

$$X_i = \begin{cases} 1, & \text{se ocorre rum de tamanho } k \text{ iniciando no } i\text{-ésimo lançamento} \\ 0 & \text{c.c.} \end{cases}$$

$$X = \sum_{i=1}^{n-k+1} X_i$$

$$E(X) = E\left(\sum_{i=1}^{n-k+1} X_i\right) = \sum_{i=1}^{n-k+1} E(X_i) = \sum_{i=1}^{n-k+1} \{1P(X_i = 1) + 0P(X_i = 0)\} = \sum_{i=1}^{n-k+1} P(X_i = 1) = \sum_{i=1}^{n-k+1} p^k \Rightarrow$$

$$E(X) = (n - k + 1)p^k.$$

8. Problema dos pareamentos ( $n$  objetos)

$X$ : Número de pareamentos

$$X = X_1 + X_2 + \dots + X_n \text{ onde}$$

$$X_i = \begin{cases} 1, & \text{há areamento na } i\text{-ésima posição} \\ 0, & \text{c.c.} \end{cases}$$

$$E(X) = E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) = \sum_{i=1}^n P(X_i = 1) = \sum_{i=1}^n \frac{(n-1)!}{n!} \Rightarrow E(X) = 1$$

**Resultado:**  $X_1, X_2, \dots, X_k$  são v.a. independentes com  $E(X_i) < \infty, i = 1, \dots, k$

Então,

$$E(X_1 * X_2 \dots * X_k) = E(X_1)E(X_2) \dots E(X_k)$$

**Resultado**  $(\Omega, \mathcal{A})$  espaço mensurável.

$$P_1, P_2 : \mathcal{A} \longrightarrow [0, 1] \text{ probabilidades.}$$

$$X : \Omega \longrightarrow \mathbb{R} \text{ v.a.}$$

$$\int_{\Omega} X dP_1 \text{ e } \int_{\Omega} X dP_2$$

$$P = \alpha P_1 + (1 - \alpha)P_2, 0 < \alpha < 1.$$

$$\text{Então; } \int_{\Omega} X dP = \alpha \int_{\Omega} X dP_1 + (1 - \alpha) \int_{\Omega} X dP_2$$



1.  $X$  simples

$$X = \sum_{i=1}^k X_i \mathbb{I}_{A_i}$$

$$\begin{aligned} \int_{\Omega} X dP &= \sum_{i=1}^k x_i P(A_i) = \sum_{i=1}^k x_i [\alpha P(A_i) + (1 - \alpha) P_2(A_i)] = \alpha \sum_{i=1}^k x_i P(A_i) + (1 - \alpha) \sum_{i=1}^k x_i P_2(A_i) \\ &= \alpha \int_{\Omega} X dP_1 + (1 - \alpha) \int_{\Omega} X dP_2 \end{aligned}$$

2.  $X \geq 0$ 

$X_n \uparrow X$ ,  $X_n \geq 0$ , simples.

$$\begin{aligned} \int_{\Omega} X dP &= \lim_{n \rightarrow \infty} \int_{\Omega} X_n dP = \lim_{n \rightarrow \infty} \left\{ \alpha \int_{\Omega} X_n dP_1 + (1 - \alpha) \int_{\Omega} X_n dP_2 \right\} = \alpha \lim_{n \rightarrow \infty} \int_{\Omega} X_n dP_1 + (1 - \alpha) \lim_{n \rightarrow \infty} \int_{\Omega} X_n dP_2 \\ &= \alpha \int_{\Omega} X dP_1 + (1 - \alpha) \int_{\Omega} X dP_2. \end{aligned}$$

$P_1(\{x_1, x_2, \dots\}) = 1$ ,  $P_2$  “possui” função densidade de probabilidade  $f_x$ , e  $X : \Omega \rightarrow \mathbb{R}$  tal que  $P(X \in A) = \alpha P_1(X^{-1}(A)) + (1 - \alpha) P_2(X^{-1}(A))$

Então:

$$E(X) = \int_{\Omega} X dP = \alpha \int_{\Omega} X dP_1 + (1 - \alpha) \int_{\Omega} X dP_2 = \alpha \sum_{i=1}^{\infty} x_i P_1(X = x_i) + (1 - \alpha) \int_{-\infty}^{\infty} x f_X(x) dx$$

**Exemplo**

$$F_X(t) = \begin{cases} 0, & t < 0 \\ \frac{1}{15} + \frac{2}{3}t, & 0 \leq t < 1 \\ 1, & t \geq 1 \end{cases}$$

IMAGEM FA F

$$\frac{1}{15} = P(X = 0) = \frac{\alpha}{1/3} P_1(X = 0) \Rightarrow P_1(X = 0) = \frac{1}{5}, \text{ e portanto, } P_1(X = 1) = \frac{4}{5}$$

$$\begin{aligned} E(X) &= \alpha \int_{\Omega} X dP_1 + (1 - \alpha) \int_{\Omega} X dP_2 = \frac{1}{3} \left\{ 0 * \frac{1}{5} + 1 * \frac{4}{5} \right\} + \frac{2}{3} \int_{-\infty}^{\infty} x f_X(x) dx = \frac{1}{3} * \frac{4}{5} + \frac{2}{3} \int_0^1 x dx = \\ &= \frac{4}{15} + \frac{2}{3} * \frac{1}{2} = \frac{9}{15}. \end{aligned}$$

**Exemplo**

$$(\Omega = [0, 1]^2, \mathcal{A} = \mathcal{B}([0, 1]^2), P = \lambda)$$

$$X(w) = \begin{cases} x_1, & w_1 \leq 1/2 \quad (A_1) \\ x_2, & w_1 > 1/2 \quad (A_2) \end{cases}$$

$$Y(w) = \begin{cases} y_1, & w_1 \leq w_2 \quad (B_1) \\ y_2, & w_1 > w_2 \quad (B_2) \end{cases}$$

IMAGEM DAS PARTIÇÕES

$$P_X(x_1) = P(X^{-1}(\{x_1\})) = P(w \in A_1) = \lambda(A_1) = 1/2$$

$$P_Y(y_1) = P(Y^{-1}(\{y_1\})) = P(w \in B_1) = \lambda(B_1) = 1/2$$

$$\sigma_X = \{\phi, A_1, A_2, \Omega\} \subseteq \mathcal{B}([0, 1]^2) \text{ (é sub-}\sigma\text{-álgebra)}$$

$$\sigma_Y = \{\phi, B_1, B_2, \Omega\} \subseteq \mathcal{B}([0, 1]^2)$$

Seja  $Z(w) = (X(w), Y(w)) = (X, Y)(w)$ ,  $Z : \Omega \rightarrow \mathbb{R}^2$   $Z(w) = \sum_{i=1}^4 z_i \mathbb{I}_{C_i}(w)$  é função simples.

$$Z(w) = \begin{cases} (x_1, y_1) = z_1, & w \in A_1 \cap B_1 = C_1 \\ (x_1, y_2) = z_2, & w \in A_1 \cap B_2 = C_2 \\ (x_2, y_1) = z_3, & w \in A_2 \cap B_1 = C_3 \\ (x_2, y_2) = z_4, & w \in A_2 \cap B_2 = C_4 \end{cases}$$

$$P_Z(\underbrace{(x_1, y_2)}_{z_2}) = P_Z(\underbrace{(x_2, y_1)}_{z_3}) = \frac{1}{8} = \lambda(\underbrace{A_1 \cap B_2}_{C_2}) = \lambda(\underbrace{A_2 \cap B_1}_{C_3})$$

$$P_Z(\underbrace{(x_1, y_1)}_{z_1}) = P_Z(\underbrace{(x_2, y_2)}_{z_4}) = \frac{3}{8} = \lambda(\underbrace{A_1 \cap B_1}_{C_1}) = \lambda(\underbrace{A_2 \cap B_2}_{C_4})$$

$$P_Z(z_1|z_1 \cap z_3) = \frac{P_Z(z_1 \cap (z_1 \cup z_3))}{P_Z(z_1 \cup z_3)} = \frac{P_Z(z_1)}{P_Z(z_1) + P_Z(z_3)} = \frac{3/8}{3/8 + 1/8} = \frac{3}{4} = P_Z((X = x_1, Y = y_1) | \overbrace{X \in \{x_1, x_2\}}^{\Omega}, Y = y_1) = P_{X|Y=y_1}(X = x_1|Y = y_1) = 1 - P_{X|y_1}(X = x_2|Y = y_1).$$

$$P_{X|y_1}(X = x_1|Y = y_2) = \frac{1/8}{4/8} = \frac{1}{4}$$

Pela aula passada, podemos calcular  $E[X|Y = y_1]$  como  $E[X|Y = y_1] = \int x dP_{X|Y=y_1}(x) = \sum_{i=1}^2 x_i P_{X|Y=y_1}(x_i|y_1)$

Por exemplo, se  $x_1 = y_1 = 1$ ,  $x_2 = y_2 = 2$ , temos  $E[X|Y = 1] = 1 * \frac{3}{4} + 2 * \frac{1}{4} = \frac{5}{4}$

Analogamente,

$$E[X|Y = 2] = 1 * \frac{1}{4} + 2 * \frac{3}{4} = \frac{7}{4}$$

$$E[X|Y](w) = \begin{cases} 5/4, & w \in B_1 \\ 7/4, & w \in B_2 \end{cases}$$

$$E[X|Y] = E[X|\sigma_X].$$

## 3.6 Aula 7

### 3.6.1 Probabilidade Condicional

#### Motivação

$P(A|B) = \frac{P(A \cap B)}{P(B)}$  é bem definido se  $P(B) > 0$ .

**Exemplo** Seja  $X : \Omega \rightarrow \mathbb{R}$  v.a. e considere um experimento em dois estagios onde seleciona-se  $X \sim F_X$  e, dado  $X = x$ ,  $0 \leq x \leq 1$ , uma moeda com probabilidade  $x$  é lançada  $n$  vezes. Nesse caso, é natural definir  $Y|X = x \sim \text{Bin}(n, x)$  mesmo que  $P(X = x) = 0$ ,  $\forall x \in [0, 1]$ .

### 3.6.2 Teorema da Medida Produto (para medidas de probabilidade)

Seja  $(\Omega_1, \mathcal{A}_1, P_1)$  um espaço de probabilidade e  $(\Omega_2, \mathcal{A}_2)$  um espaço mensurável. Para cada  $w_1 \in \Omega_1$ , defina uma medida de probabilidade  $\mu(w_1, \cdot)$  em  $\mathcal{A}_2$ . Assuma que, para cada  $B \in \mathcal{A}_2$ ,  $\mu(\cdot, B)$  também é  $\mathcal{A}_1$ -mensurável. Então, existe uma única medida de probabilidade  $P$  em  $\mathcal{A} = \mathcal{A}_1 \times \mathcal{A}_2$  tal que  $P(A \times B) = \int_A \mu(w_1, B) dP_1(w_1)$ ,  $\forall A \in \mathcal{A}_1$ ,  $\forall B \in \mathcal{A}_2$ .

Se  $D(w_1)$  denota uma secção de  $D$  em  $w_1$ , isto é,  $D(w_1) = \{w_2 \in \Omega_2 : (w_1, w_2) \in D\}$ ,  $D \in \mathcal{A} = \mathcal{A}_1 \times \mathcal{A}_2$ , então

$$P(D) = \int_{\Omega_1} \mu(w_1, D(w_1)) dP_1(w_1).$$

Voltando à probabilidade condicional,

Vamos interpretar (informalmente por enquanto)  $\mu(x, B)$  como  $P(Y \in B|X = x)$ . Ainda informalmente, vamos pensar no evento  $\{X = x\}$ . Intuitivamente, a probabilidade que  $X \in (x, x + dx]$  é  $dF(x)$ .

Então, sabendo que  $\{X = x\}$ , o evento  $\{(X, Y) \in C\}$  ocorre se, e somente,  $Y \in C(x) = \{y : (x, y) \in C\}$  e a probabilidade desse evento é  $\mu(x, C(x))$ . Pela regra da probabilidade total,

$$P(C) = \int_{-\infty}^{\infty} \mu(x, C(x)) dF(x).$$

Se  $C = \{(x, y) : x \in A, y \in B\} = A \times B$ ,  $C(x) = B$  se  $x \in A$  e  $C(x) = \emptyset$  se  $x \notin A$ , então

$$P(C) = P(A \times B) = \int_A \mu(x, B) dF(x)$$

Se  $\mu(x, B)$  é mensurável em  $x$  para cada  $B \in \mathcal{B}(\mathbb{R})$ , então pelo Teorema anterior,  $P$  é único.

**Exemplo:** Se  $X \sim \text{Beta}(a, b)$  e  $Y|X = x \sim \text{Ben}(n, x)$  ( $\Omega_1 = [0, 1]$ ,  $\mathcal{A}_1 = \mathcal{B}([0, 1])$ ,  $P_X$ ), onde

$$P_X(A) = \int_A dF_X(x) = \int_A f_X(x) dx = \int_A \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} dx$$

para  $A \in \mathcal{A}_1$ . Além disso, considere  $\Omega_2 = \{0, 1, \dots, n\}$ ,  $\mathcal{A}_2 = \mathcal{P}(\Omega_2)$  e, para cada  $x \in [0, 1]$ ,

$\mu(x, B) = P(Y \in B|X = x)$ . Então, pra  $k = 0, 1, \dots, n$ ;  $\mu(x, B) = P(Y \in B|X = x) = \binom{n}{k} x^k (1-x)^{n-k}$  (que é mensurável em  $x$ ).

Tomando  $\Omega = \Omega_1 \times \Omega_2$ ,  $\mathcal{A} = \mathcal{A}_1 \times \mathcal{A}_2$ ,  $P$  é a única medida de probabilidade determinada por  $P_X$  (ou  $F_X$ ) e  $\mu(x, \cdot)$ .

$$P(C) = \int_{\Omega_1} \mu(x, C(x)) dP_X = \int_0^1 \mu(x, C(x)) dF_X(x) = \int_0^1 \mu(x, C(x)) f_X(x) dx, C \in \mathcal{A}.$$

Por exemplo, se  $C = \Omega_1 \times \{k\}$ , temos

$$\begin{aligned} P(Y = k) &= P(\Omega_1 \times \{k\}) = \int_0^1 P(Y = k|X = x) dF(x) = \int_0^1 \binom{n}{k} x^k (1-x)^{n-k} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} dx \\ &= \frac{\binom{n}{k} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}}{\frac{\Gamma(a+b+n)}{\Gamma(a+k)\Gamma(b+n-k)}} \int_0^1 \frac{\Gamma(a+b+n)}{\Gamma(a+k)\Gamma(b+n-k)} x^{a+k-1} (1-x)^{b+n-k-1} dx = \binom{n}{k} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \frac{\Gamma(a+k)\Gamma(b+n-k)}{\Gamma(a+b+n)} \end{aligned}$$

( $Y \sim \text{BetaBin}(n, a, b)$ )

**Teorema**  $X : (\Omega, \mathcal{A}) \rightarrow (\mathfrak{X}, \mathcal{F})$  em  $(\Omega, \mathcal{A}, P)$  e  $B \in \mathcal{A}$ . Então  $\exists g : \mathfrak{X} \rightarrow \mathbb{R}$  tal que, para cada  $A \in \mathcal{F}$ ,  $P(\{x \in A\} \cap B) = \int_A g(x) dP_X(x)$ .

Além disso,  $g$  é única  $P_X$ -q.c.

( $g(x) = P(B|X = x)$  é única  $P_X$ -q.c. para um dado  $B$ )

**Demo:** segue diretamente do Teorema de Radon-Nikodim (se  $\mu(A) = P(\{x \in A\} \cap B)$  então  $\lambda$  é medida finita em  $\mathcal{F}$  com  $\lambda \ll P_X$ )

**Exemplo1:**  $\mathfrak{X} = \{x_1, x_2, \dots\}$  com  $p_i = P(\{X = x_i\}) > 0$ . Defina

$$g(x_i) = P(B|X = x_i) = \frac{P(B \cap \{X = x_i\})}{P(\{X = x_i\})}, i = 1, 2, \dots$$

( $g$  é uma “proposta” para  $P(B|\{X = x_i\})$ )

Se  $A \in \mathcal{F} = \mathcal{P}(\mathfrak{X})$ ,

$$\int_A g(x) dP_X(x) = \int_{\mathfrak{X}} g(x) \mathbb{1}_A(x) dP_X(x) = \sum_{i=1}^{\infty} g(x_i) \mathbb{1}_A(x_i) P_X(\{x_i\}) = \sum_{x_i \in A} g(x_i) P(\{X = x_i\}) = \sum_{x_i \in A} P(B \cap \{X = x_i\}) = P(\{X \in A\} \cap B).$$

**Exemplo 2**  $\Omega = \mathbb{R}^2$ ,  $\mathcal{A} = \mathcal{B}(\mathbb{R}^2)$ ,  $X(x, y) = x$ ,  $Y(x, y) = y$  ( $X, Y$ ) v.a. com densidade  $f$  ( $P(A) = \int_A f(x, y) dx dy$ ,  $A \in \mathcal{A}$ ).

Nesse caso  $P(\{X = x\}) = 0, \forall x$ .

Seja  $f_1(x) = \int_{-\infty}^{\infty} f(x, y) dy$  a densidade de  $X$ .

Defina  $f(y|x) = \frac{f(x, y)}{f_1(x)}$  como a densidade condicional de  $Y$  dado  $X = x$ .

Note que  $f(y|x)$  só está definido quando  $f_1(x) \neq 0$ .

Contudo, se  $S = \{(x, y) : f_1(x) = 0\}$  então  $P(\{(X, Y) \in S\}) = 0$

$$P(\{(X, Y) \in S\}) = \int \int_S f(x, y) dx dy = \int_{\{x: f_1(x)=0\}} \left[ \int_{-\infty}^{\infty} f(x, y) dy \right] dx = \int_{\{x: f_1(x)=0\}} f_1(x) dx = 0.$$

de modo que podemos ignorar o conjunto onde  $f(y|x)$  não está definida.

Se  $X = x$ ,  $\forall B \in \mathcal{A}$ ,  $B$  ocorre se e soente se  $Y \in B(x) = \{y : (x, y) \in B\}$ . Assim, vamos propor

$$g(x) = P(\{Y \in B(x) | X = x\}) = \int_{B(x)} f(y|x) dy = \int_{-\infty}^{\infty} \mathbb{I}_B(x, y) f(y|x) dy,$$

Então, se  $A \in \mathcal{B}(\mathbb{R})$ ,

$$\begin{aligned} P(\{X \in A\} \cap B) &= \int \int_{\substack{x \in A \\ (x, y) \in B}} f(x, y) dx dy = \int_{-\infty}^{\infty} \left[ \int_{-\infty}^{\infty} \mathbb{I}_B(x, y) f(y|x) dy \right] \mathbb{I}_A(x) f_1(x) dx = \int_A f_1(x) dx \underbrace{\int_B f(y|x) dy}_{g(x)} dx = \\ &= \int_A g(x) f_1(x) dx = \int_A g(x) dP_X(x) \\ \Rightarrow g(x) &= P(B|X = x) \end{aligned}$$

$$P(X \in A, Y \in B) = \int_A \int_B f(x, y) dx dy = \int_A \int_B f(y|x) f_1(x) dy dx = \int_B \int_A f(x|y) f_2(y) dx dy$$

# Referências Bibliográficas

DeGroot, M. H. (1970). *Optimal Statistical Decisions*. MacGraw-Hill, New York.